

Quel rôle jouent respectivement les prévisions de volatilité et de corrélation dans l'efficacité des stratégies d'allocation minimum-variance ?

Luca Silva

Année universitaire 2025–2026

Mémoire de Master

Master 2 Gestion des Risques et des Actifs à l'Université Paris-Saclay

Sous la supervision de Pierre Clauss

Résumé

Ce mémoire étudie le rôle respectif des prévisions de volatilité et de corrélation dans l'efficacité des stratégies d'allocation minimum-variance, mesurée par le risque *réalisé* hors échantillon du portefeuille minimum-variance global, conformément au critère d'Engle et Colacito (2006). À partir de la décomposition $\Sigma_t = D_t R_t D_t$, une grille factorielle croisant deux modèles de variance (empirique, GARCH(1,1)) et trois modèles de corrélation (empirique, shrinkage de Ledoit et Wolf, DCC) est backtestée sur 281 actions américaines entre 2005 et 2025, pour $N \in \{50, 100, 200\}$. Les résultats montrent que le shrinkage de la corrélation réduit systématiquement et significativement le risque réalisé, avec un gain qui croît avec N , tandis que le GARCH détériore ce même risque et que le DCC n'apporte de gain robuste dans aucune configuration. Une robustesse en contrainte long-only nuance cette hiérarchie sans la renverser : elle rend l'effet délétère du GARCH non significatif, ce qui suggère que la contrainte de poids agit elle-même comme une régularisation implicite.

Mots-clés : portefeuille minimum-variance ; matrice de covariance ; GARCH ; DCC ; shrinkage de corrélation ; Engle–Colacito ; attribution factorielle.

Table des matières

Introduction	5
1 Revue de littérature : deux remèdes qui s'ignorent	7
1.1 Le problème : erreur d'estimation et portefeuille optimal	7
1.2 L'axe temporel : d'ARCH à DCC	8
1.3 L'axe cross-sectionnel : du biais spectral au shrinkage	8
1.4 Le mariage des deux axes	9
1.5 La valeur économique et la décomposition D/R	9
1.6 Synthèse critique : le trou dans la littérature	10
2 Méthodologie : la grille $D \times R$ et son protocole d'évaluation	12
2.1 Cadre théorique	12
2.1.1 Le portefeuille minimum-variance global	12
2.1.2 Le résultat d'Engle et Colacito : évaluer sans observer	13
2.2 La décomposition $\Sigma_t = D_t R_t D_t$	14
2.2.1 Définition	14
2.2.2 Portée pratique de la décomposition	15
2.3 Modèles de variances (brique D)	15
2.3.1 Variance empirique glissante	15
2.3.2 GARCH(1,1)	15
2.4 Modèles de corrélations (brique R)	16
2.4.1 Corrélation empirique constante	16
2.4.2 Corrélation constante shrinkée (Ledoit–Wolf)	17
2.4.3 Corrélation conditionnelle dynamique (DCC scalaire)	17
2.5 La grille de croisements et sa lecture en différences	18
2.6 Protocole de backtest	19
2.6.1 Robustesse : contrainte long-only	19
2.7 Inférence statistique et économique	20
2.7.1 Perte quadratique et test de Diebold–Mariano	20
2.7.2 Valeur économique : coûts et <i>performance fee</i>	21
2.8 Hypothèses testables	21
3 Données	23
3.1 Univers	23
3.2 Source et nettoyage	23
3.3 Protocole temporel	24
3.4 Statistiques descriptives	24
3.4.1 Corrélation moyenne par régime	25
3.4.2 Ratio N/T des configurations	25

4	Résultats	26
4.1	Classement descriptif des six cellules	26
4.2	Effet de la volatilité (D)	26
4.3	Effet de la corrélation (R)	27
4.4	Interaction $D \times R$	28
4.5	Effet de la dimension N	28
4.6	Régimes de marché	29
4.7	Turnover, exposition et valeur économique	29
4.8	Confrontation aux hypothèses	30
4.9	Robustesses	31
5	Limites et extensions	33
5.1	Limites	33
5.2	Extensions	33
	Conclusion	35
	Bibliographie	37
	Annexe A — Liste des actions retenues	40

Liste des tableaux

2.1	La grille $D \times R$	18
3.1	Construction du panel	24
3.2	Fenêtre glissante et échantillon hors échantillon	24
3.3	Statistiques descriptives (moyenne cross-section, 281 actions, échantillon complet)	24
3.4	Corrélation moyenne de paire par sous-période	25
3.5	Ratio N/T par configuration	25
4.1	Écart-type annualisé des rendements GMV réalisés (%)	26
4.2	Effet de D (GARCH – empirique), à R fixé	27
4.3	Effet de R , à D fixé	27
4.4	Interactions $D \times R$ (écart de perte quadratique moyenne $\times 10^{-6}$, statistique DM, p-value)	28
4.5	Turnover mensuel moyen et exposition brute ($N = 100$)	30
4.6	Performance fee annuel net de coûts (points de base, $\gamma = 10$, $N = 100$) . .	31

Table des figures

2.1	Ordre des opérations à une date de rebalancement t . La décomposition $D \times R$ (deux cases centrales) est la seule étape qui distingue les six cellules de la grille ; le solveur GMV et la logique de détention sont partagés. . . .	15
4.1	Écart-type annualisé réalisé par cellule et par dimension N	29
4.2	Effets d'attribution D/R par dimension N	30

Introduction

Markowitz (1952) formalise, il y a plus de soixante-dix ans, l'idée que la diversification peut être optimisée : un investisseur rationnel devrait choisir, parmi tous les portefeuilles atteignant un rendement espéré donné, celui dont la variance est la plus faible. L'idée est devenue un pilier de la théorie du portefeuille ; sa mise en œuvre pratique reste, paradoxalement, une source persistante de déception. Michaud (1989) resitue précisément le problème : loin de corriger les erreurs d'estimation des rendements espérés et des covariances, l'optimiseur de Markowitz les *amplifie*. Il qualifie d'ailleurs l'optimisation moyenne-variance d'« *error maximizer* ». Le mémoire se concentre sur la version la plus épurée de ce problème, le portefeuille minimum-variance global (GMV), qui élimine l'erreur d'estimation sur les rendements espérés en ne contraignant que le budget d'investissement (chapitre 2, §2.1.1) : ce faisant, il isole entièrement la question sur la seule matrice de covariance.

Cette question n'est pas seulement académique. Sur le seul segment des fonds négociés en bourse domiciliés aux États-Unis, les stratégies « low-volatility » et « minimum-volatility » représentaient, en mars 2025, un encours cumulé d'environ 47,7 milliards de dollars répartis sur 19 fonds, dont à eux seuls 23,5 milliards pour l'iShares MSCI USA Minimum Volatility Factor ETF (USMV) et 7,6 milliards pour l'Invesco S&P 500 Low Volatility ETF (SPLV)¹. Ces véhicules reposent, explicitement ou non, sur une estimation de la matrice de covariance des actifs sous-jacents : la qualité de cette estimation a donc une traduction directe et chiffrable en performance réalisée pour des dizaines de milliards de dollars d'encours.

L'estimation d'une matrice de covariance Σ_t pour N actifs souffre en réalité de deux maladies, deux difficultés bien distinctes. La première est *temporelle* : la volatilité des rendements financiers n'est pas constante, elle s'agrège en régimes de calme et de tension (*volatility clustering*), un fait stylisé qui a motivé toute la famille des modèles ARCH/GARCH (chapitre 1, §1.2) et leurs extensions multivariées. La seconde est *cross-sectionnelle* : dès que le nombre d'actifs N n'est plus négligeable devant le nombre d'observations T disponibles pour l'estimer, la matrice de covariance *empirique* elle-même devient un estimateur bruité, dont les valeurs propres extrêmes sont systématiquement biaisées (loi de Marčenko–Pastur, chapitre 1, §1.3), un biais que corrige la famille des estimateurs à rétrécissement (*shrinkage*). Ces deux remèdes ont été développés, pour l'essentiel, par deux littératures qui se sont longtemps ignorées, et que seuls des travaux récents commencent à faire dialoguer (chapitre 1, §1.4).

Avant d'aller plus loin, quelques définitions doivent être fixées précisément. La **covariance conditionnelle** Σ_t désigne la matrice de covariance des rendements futurs r_{t+1} ,

1. ETF Database (etfdb.com), « Low Volatility ETF List », consulté en 2026 ; les chiffres cités datent de mars 2025 et ne couvrent que les véhicules cotés aux États-Unis. L'encours institutionnel mondial mobilisant des constructions minimum-variance, en mandat direct ou via des fonds non cotés, est nécessairement bien supérieur.

conditionnelle à l'information disponible en t : c'est un objet qui varie dans le temps, et non un paramètre constant estimé une fois pour toutes.

Le **portefeuille minimum-variance** (GMV) est le portefeuille de poids w_t , satisfaisant la seule contrainte budgétaire $\mathbf{1}^\top w_t = 1$, qui minimise $w_t^\top \Sigma_t w_t$ (chapitre 2, §2.1.1).

Une **prévision hors échantillon** (*out-of-sample*) est une prévision de Σ_t construite exclusivement à partir d'observations strictement antérieures à t , puis confrontée à des rendements réalisés que le modèle n'a jamais utilisés pour s'ajuster : c'est une condition indispensable pour que la comparaison entre modèles soit informative plutôt que circulaire.

L'**efficacité** d'une stratégie minimum-variance, au sens de ce mémoire, désigne sa capacité à atteindre son objectif déclaré : minimiser le risque *réalisé* du portefeuille hors échantillon. Le critère principal en est donc la variance, ou l'écart-type annualisé, des rendements réalisés (chapitre 2, §2.1.2) ; le turnover, les coûts de transaction et la valeur économique nette (chapitre 2, §2.7.2) sont des critères secondaires, qui complètent ce critère principal sans jamais s'y substituer.

La question centrale du mémoire découle directement de ces deux difficultés d'estimation et du cadre qui vient d'être posé : elle vient se poser dans les termes suivants :

Quel rôle jouent respectivement les prévisions de volatilité et de corrélation dans l'efficacité des stratégies d'allocation minimum-variance ?

Cette question se traduit empiriquement, via la décomposition $\Sigma_t = D_t R_t D_t$ (chapitre 2, §2.2), en une question d'attribution : quelle part de la réduction du risque réalisé provient de la prévision des volatilités individuelles (D_t), quelle part de celle des corrélations (R_t) ? Elle se décline en trois sous-questions, qui structurent la lecture des résultats (chapitre 4) :

- SQ1** Les gains documentés séparément par la littérature (volatilité GARCH, corrélation shrinkée, corrélation dynamique) se confirment-ils sous un protocole d'évaluation *unifié*, fondé sur la variance réalisée hors échantillon de portefeuilles minimum-variance et des tests de significativité de type Diebold–Mariano ?
- SQ2** En croisant systématiquement les modèles de volatilité et de corrélation via la grille $D \times R$, quelle brique explique l'essentiel de la réduction de risque observée, et ce diagnostic dépend-il de la taille N de l'univers ?
- SQ3** La hiérarchie « la volatilité compte davantage que la corrélation », suggérée en petite dimension par Chopra et Ziemba (1993) et par la construction bivariée d'Engle et Colacito (2006), survit-elle en dimension moyenne et grande, là où l'erreur d'estimation cross-sectionnelle de la corrélation s'aggrave ?

Le mémoire se limite à un univers d'actions cotées, à des rendements journaliers, et retient la variance réalisée hors échantillon comme critère de risque : les extensions à d'autres classes d'actifs, à des données intrajournalières, ou à des critères de risque de queue (*value-at-risk*, *expected shortfall*) sont explicitement hors périmètre et discutées comme pistes de prolongement (chapitre 5). Le chapitre 1 situe la contribution du mémoire dans les deux littératures évoquées ci-dessus. Le chapitre 2 pose le cadre théorique : dérivation du GMV, justification de la variance réalisée comme fonction de perte, décomposition $D \times R$, et le protocole empirique qui en découle. Le chapitre 3 décrit les données. Le chapitre 4 présente et discute les résultats, à la lumière des trois sous-questions ci-dessus. Le chapitre 5 en tire les limites et les prolongements possibles, avant la conclusion.

1 Revue de littérature : deux remèdes qui s'ignorent

L'estimation d'une matrice de covariance destinée à l'allocation de portefeuille souffre de deux maux distincts, traités historiquement par deux littératures qui se sont longtemps ignorées : un mal *temporel* (la covariance change dans le temps, ce que corrige la famille ARCH/GARCH et ses extensions multivariées) et un mal *cross-sectionnel* (la covariance est mal conditionnée en grande dimension, ce que corrige le shrinkage). Ce chapitre retrace ces deux axes (§1.2 et §1.3), leur rapprochement récent (§1.4), puis la littérature, plus fragmentaire, qui évalue la valeur économique de ces remèdes plutôt que leur seule précision statistique (§1.5), avant d'identifier précisément, en §1.6, le point que ni l'un ni l'autre axe ne couvre et que le mémoire se propose de combler.

1.1 Le problème : erreur d'estimation et portefeuille optimal

Markowitz (1952) fonde l'allocation de portefeuille sur deux quantités estimées : le vecteur des rendements espérés et la matrice de covariance. Michaud (1989) montre que l'optimiseur moyenne-variance, loin de corriger les erreurs d'estimation de ces deux quantités, les amplifie mécaniquement : il qualifie l'optimisation de Markowitz d'« *error maximizer* ». L'intuition est spectrale : le programme d'optimisation pondère chaque direction propre de la matrice de covariance par l'inverse de sa valeur propre ; les directions les moins bien estimées, typiquement celles associées aux plus petites valeurs propres et les plus sensibles au bruit d'échantillonnage, reçoivent ainsi mécaniquement le plus de poids dans la solution optimale. Une petite erreur d'estimation dans une direction propre faible peut donc produire un poids de portefeuille arbitrairement grand.

Chopra et Ziemba (1993) quantifient ce phénomène par simulation : les erreurs sur les rendements espérés dégradent la performance du portefeuille optimal environ dix fois plus que les erreurs de même ampleur relative sur les variances, et environ vingt fois plus que sur les covariances, mais cette hiérarchie s'inverse à mesure que l'aversion au risque de l'investisseur augmente, la matrice de covariance devenant alors le principal facteur de risque d'estimation. C'est cette dernière configuration que le portefeuille minimum-variance global (GMV) isole délibérément : en ne contraignant que le budget et jamais les rendements espérés (chapitre 2, §2.1.1), le GMV élimine structurellement l'erreur d'estimation sur les rendements espérés du problème, et concentre tout le risque d'estimation résiduel sur la seule matrice Σ . C'est ce qui rend le GMV, plutôt qu'un portefeuille tangent ou une allocation moyenne-variance générale, l'instrument approprié pour isoler et comparer des estimateurs de covariance concurrents, indépendamment de la question, distincte, de la prévision des rendements.

1.2 L'axe temporel : d'ARCH à DCC

Engle (1982) introduit le modèle ARCH : la variance conditionnelle d'un rendement dépend de ses chocs passés, ce qui permet de capturer les regroupements de volatilité (*volatility clustering*) observés sur les séries financières. Bollerslev (1986) généralise ce modèle en GARCH, en ajoutant une dépendance à la variance conditionnelle passée elle-même ; le GARCH(1,1), avec un unique terme autorégressif et un unique terme de moyenne mobile, reste, près de quarante ans plus tard, la spécification de référence pour la volatilité univariée journalière, difficile à surpasser significativement par des spécifications plus riches (constat que confirme, entre autres, la comparaison de modèles menée par Halbleib et Voev, §1.5).

L'extension au cas multivarié pose un problème de dimensionnalité : une matrice de covariance conditionnelle $N \times N$ compte $N(N+1)/2$ éléments à modéliser dynamiquement, ce qui devient vite intraitable en grande dimension. Bollerslev (1990) propose une première solution : le modèle à corrélation conditionnelle constante (CCC), qui décompose la covariance conditionnelle en volatilités individuelles GARCH, dynamiques, et une matrice de corrélation *constante* dans le temps. Cette décomposition, $\Sigma_t = D_t R D_t$ avec R fixe, est l'ancêtre direct de la décomposition $\Sigma_t = D_t R_t D_t$ utilisée dans ce mémoire (chapitre 2, §2.2) : le CCC en est le cas particulier où $R_t = R$ ne varie pas. Engle (2002) relâche cette dernière contrainte avec le modèle à corrélation conditionnelle dynamique (DCC) : la corrélation suit elle-même une dynamique autorégressive scalaire simple, estimée en deux étapes, les volatilités univariées d'abord puis la dynamique de corrélation sur les résidus dévolatilisés, ce qui rend le modèle tractable même en grande dimension, sans jamais requérir l'estimation simultanée de tous les paramètres. C'est exactement cette procédure en deux étapes que reproduit la brique DCC du mémoire (chapitre 2, §2.4.3).

1.3 L'axe cross-sectionnel : du biais spectral au shrinkage

Indépendamment de toute dynamique temporelle, la matrice de covariance *empirique* elle-même est un estimateur de mauvaise qualité dès que la dimension N n'est pas négligeable devant le nombre d'observations T . La théorie des matrices aléatoires, en particulier la loi de Marčenko–Pastur qui décrit la distribution asymptotique des valeurs propres d'une matrice de covariance empirique construite à partir de bruit pur, montre que cet estimateur souffre d'un biais spectral systématique : ses plus grandes valeurs propres sont surestimées et ses plus petites sous-estimées, un biais qui croît avec le ratio N/T (ce ratio, central pour le mémoire, est étudié explicitement au chapitre 3, §3.4.2). Ce biais spectral est précisément ce qui alimente l'« *error maximizer* » de Michaud (1989) : les directions propres les plus mal estimées de la matrice empirique sont celles auxquelles l'optimiseur minimum-variance accorde, via Σ^{-1} , le plus de poids.

Ledoit et Wolf (2004) proposent un remède direct : plutôt que d'utiliser telle quelle la matrice de corrélation empirique, on la rapproche (on la *contracte*, ou *shrink*) d'une cible plus stable et mieux conditionnée, par exemple la matrice identité. L'estimateur final est une moyenne pondérée entre la corrélation empirique et cette cible, et le poids accordé à la cible est choisi pour minimiser l'écart attendu entre cet estimateur et la véritable corrélation. Ce shrinkage *linéaire*, appliqué à la brique de corrélation R , est la méthode retenue dans ce mémoire (chapitre 2, §2.4.2).

Les auteurs proposent ensuite une version plus élaborée, le shrinkage *non linéaire* (Ledoit et Wolf, 2012) : au lieu d'appliquer le même poids de correction à toutes les valeurs

propres de la matrice, chacune est corrigée individuellement, selon son propre niveau de biais. Ledoit et Wolf (2017) montrent que cette version plus fine réduit encore le risque réalisé d'un portefeuille minimum-variance, par rapport au shrinkage linéaire. Ce raffinement n'a volontairement pas été retenu comme septième modèle de la grille : l'ajouter aurait complexifié le protocole sans changer la question posée par ce mémoire, centrée sur l'arbitrage entre dynamique temporelle et régularisation cross-sectionnelle plutôt que sur le réglage optimal de cette dernière (voir chapitre des limites et extensions).

1.4 Le mariage des deux axes

Les deux littératures précédentes restent, pour l'essentiel, étanches l'une à l'autre : la famille GARCH/DCC traite la dynamique temporelle sans se soucier du biais spectral en grande dimension ; le shrinkage traite le biais spectral sans dynamique temporelle. Engle, Ledoit et Wolf (2019) marient explicitement les deux remèdes : leur modèle combine un DCC estimé sur des résidus GARCH univariés (axe temporel) et une cible de corrélation shrinkée non linéairement (axe cross-sectionnel), et documentent, sur un large panel d'actions américaines et un protocole de portefeuille GMV en fenêtre glissante, un gain substantiel de risque réalisé par rapport à l'estimateur empirique statique. Ce protocole, univers large, sélection dynamique par liquidité, GMV non contraint en fenêtre glissante, est directement celui retenu par ce mémoire (chapitre 2, §2.6). Des prolongements plus récents (De Nard, Ledoit et Wolf, 2021) explorent des combinaisons alternatives de structure à facteurs et de shrinkage non linéaire en très grande dimension, dans le prolongement direct de ce programme de recherche.

Le point aveugle de ce mariage, cependant, est méthodologique : le DCC-NL d'Engle, Ledoit et Wolf (2019) est un modèle *intégré*, où la brique temporelle et la brique cross-sectionnelle sont ajustées et évaluées ensemble, comme un seul objet. Rien, dans leur protocole, ne permet de distinguer si le gain observé provient principalement de la dynamique DCC, du shrinkage non linéaire, ou de leur interaction. C'est précisément cette question, déjà posée par Chopra et Ziemba (1993) mais jamais opérée sur un plan factoriel systématique en grande dimension, que ce mémoire cherche à trancher.

1.5 La valeur économique et la décomposition D/R

Une littérature plus restreinte évalue les estimateurs de covariance non plus par une distance statistique à une cible (MSE, vraisemblance), mais par leur valeur *économique* pour l'allocation. Engle et Colacito (2006) fondent ce courant : leur résultat, démontré et exploité au chapitre 2 (§2.1.2), établit que la variance réalisée d'un portefeuille minimum-variance construit à partir d'un estimateur candidat fournit un critère de classement valide entre estimateurs, sans jamais requérir d'observer la véritable covariance. Leur application reste toutefois limitée à la dimension deux et à des données simulées ; ils ne proposent aucune grille systématique croisant plusieurs modèles de volatilité et de corrélation.

Fleming, Kirby et Ostdiek (2001, 2003) évaluent, dans le même esprit économique, la valeur du *timing* de la volatilité : un investisseur qui ajuste dynamiquement son allocation à la volatilité prévue plutôt que de la supposer constante réalise un gain quantifiable, mesuré par un *performance fee* fondé sur l'utilité espérée, exactement l'outil repris au chapitre 2 (§2.7.2) pour traduire les écarts de risque et de rendement de la grille en un montant unique. Pouliasis et Papapostolou (2018) étendent cette logique de *timing* économique à la corrélation en plus de la volatilité, sur des marchés à terme, mais actif

par actif et classe d’actifs par classe d’actifs, sans grille factorielle systématique croisant les deux dimensions.

La modélisation *séparée* des volatilités et des corrélations, condition préalable à toute attribution, est explorée par Halbleib et Voev (2011/2016) : leur approche mixte prévoit les volatilités à partir de données haute fréquence et les corrélations à partir de données journalières, deux sources d’information distinctes dont le mélange réduit, par construction, la dépendance entre les deux erreurs de prévision. Leur critère d’évaluation reste néanmoins une erreur quadratique moyenne par rapport à une covariance réalisée intra-journalière, non une fonction de perte économique ; les auteurs signalent d’ailleurs explicitement qu’une évaluation par la variance de portefeuille sort du cadre de leur article et relève d’une étude séparée. Oh et Patton (2016) et Bollerslev, Patton et Quaedly (2018) poursuivent, chacun à leur manière, cette logique de modélisation séparée des deux composantes ; ces derniers, en particulier, formalisent une architecture volatilité–corrélations de type DRD, la même décomposition que celle retenue par ce mémoire, et évaluent leurs prévisions par des décisions de portefeuille plutôt que par une simple MSE matricielle, documentant des gains nets de coûts de l’ordre de 60 à 170 points de base annuels pour des architectures DRD comparables à celle étudiée ici.

Deux lectures plus récentes, extérieures au corpus initial du plan de mémoire, précisent encore ce paysage. Santos (2019), malgré un titre très proche de la problématique de ce mémoire, poursuit en réalité une question différente : il décompose algébriquement les poids d’une *unique* matrice de covariance en une partie diagonale et une partie hors-diagonale, et compare cette dernière à son absence pure et simple (portefeuille diagonal, équivalent au *volatility timing* de Kirby et Ostdiek), sans jamais comparer entre eux plusieurs modèles concurrents de corrélation. Il documente néanmoins, en données réelles et net de coûts de transaction, que la composante hors-diagonale devient souvent délétère, un avertissement sur le rôle du turnover que confirme, dans une tout autre configuration, la section sur la valeur économique du chapitre de résultats. Dom, Howard, Jansen et Lohre (2025) apportent un second éclairage, complémentaire : sur un panel S&P 500 indépendant (1990–2021), ils montrent que l’avantage des estimateurs de covariance sophistiqués sur l’estimateur empirique, substantiel sous portefeuille minimum-variance non contraint, s’effondre presque entièrement dès qu’une contrainte réaliste de type long-only est imposée. Ni l’un ni l’autre, cependant, ne décompose la matrice de covariance en plusieurs modèles concurrents de volatilité *et* de corrélation : chacun de leurs estimateurs reste un objet unique ou un paquet complet.

1.6 Synthèse critique : le trou dans la littérature

Aucun des travaux recensés ne réunit simultanément les quatre éléments du protocole retenu ici : (i) une grille *factorielle*, croisant plusieurs modèles concurrents de volatilité et plusieurs modèles concurrents de corrélation, permettant d’isoler l’effet propre de chaque brique et leur interaction ; (ii) un critère d’évaluation *économique* : plutôt que de juger un estimateur de covariance en mesurant son écart statistique à une matrice de référence (une erreur quadratique, par exemple), on observe s’il réduit réellement le risque d’un portefeuille minimum-variance construit à partir de lui, ce que justifie théoriquement Engle et Colacito (2006) ; (iii) des données *réelles*, journalières, sur un large univers d’actions, plutôt que la dimension deux ou les simulations d’Engle et Colacito (2006) ; (iv) une lecture systématique de cette attribution en fonction de la *dimension* N de l’univers, c’est-à-dire un test qui ne se contente pas d’une seule taille d’univers mais qui regarde si la réponse

change quand N augmente. Ce dernier point est nécessaire pour trancher entre deux intuitions qui se contredisent : en petite dimension, Chopra et Ziemba (1993) montrent que les erreurs sur la volatilité pèsent plus lourd que les erreurs sur la corrélation ; mais lorsque N augmente par rapport au nombre d’observations T , la théorie de Marčenko–Pastur (§1.3) prédit au contraire que l’erreur d’estimation de la corrélation empirique elle-même s’aggrave. Il fallait donc vérifier laquelle de ces deux forces l’emporte à mesure que la dimension augmente, plutôt que de trancher a priori.

Engle et Colacito (2006) fournissent le critère économique (ii) mais pas la grille factorielle (i), ni (iii) ni (iv) ; Engle, Ledoit et Wolf (2019) fournissent la grande dimension (iii) et une combinaison des deux remèdes, mais aucune décomposition factorielle (i) ; Bollerslev, Patton et Quaadvlieg (2018) et Halbleib et Voev (2011/2016) séparent volatilité et corrélation à la prévision, condition nécessaire à (i), mais évaluent par une distance statistique plutôt que par (ii) ; Santos (2019) et Dom, Howard, Jansen et Lohre (2025) confirment, chacun sur un terrain distinct, l’importance des contraintes de portefeuille et du turnover, sans jamais opérer la décomposition factorielle (i). C’est ce croisement des quatre éléments, grille factorielle, critère économique, données réelles, lecture par dimension, que ce mémoire assemble, en s’appuyant sur les briques économétriques validées par chacun de ces courants sans en emprunter le dessin expérimental à aucun d’entre eux.

2 Méthodologie : la grille $D \times R$ et son protocole d'évaluation

Ce chapitre pose le cadre théorique et opérationnel qui permet de répondre à la problématique. La section 2.1 établit les deux résultats sur lesquels repose tout le protocole : la dérivation du portefeuille minimum-variance global (GMV) et sa solution fermée, puis le résultat d'Engle et Colacito (2006) qui justifie l'usage de la variance réalisée hors échantillon comme fonction de perte, sans jamais avoir besoin d'observer la véritable matrice de covariance. La section 2.2 introduit la décomposition $\Sigma_t = D_t R_t D_t$ et démontre sa validité et son unicité. Les sections 2.3 et 2.4 détaillent respectivement les modèles retenus pour la brique de volatilité (D) et pour la brique de corrélation (R). La section 2.5 assemble ces briques en une grille de six matrices de covariance et explicite la lecture en différences qui permet l'attribution. Les sections 2.6 et 2.7 précisent le protocole de backtest et les outils d'inférence statistique et économique. La section 2.8 formule les cinq hypothèses testables qui structurent la lecture des résultats au chapitre suivant.

2.1 Cadre théorique

2.1.1 Le portefeuille minimum-variance global

Soit $r_{t+1} \in \mathbb{R}^N$ le vecteur des rendements futurs (inconnus à la date t) de N actifs, et $\Sigma_t = \text{Var}_t(r_{t+1})$ leur matrice de covariance conditionnelle, supposée définie positive. Le portefeuille minimum-variance global résout le programme

$$\min_{w \in \mathbb{R}^N} w^\top \Sigma_t w \quad \text{sous} \quad \mathbf{1}^\top w = 1, \quad (2.1)$$

où $\mathbf{1}$ désigne le vecteur de uns. Aucune contrainte n'est imposée sur les rendements espérés : c'est un choix délibéré, qui remonte à Chopra et Ziemba (1993). En ne contraignant que le budget, tout le risque du portefeuille optimal provient exclusivement de l'erreur d'estimation sur Σ_t : les rendements espérés n'interviennent nulle part dans le programme. C'est un avantage pratique important, car ils sont beaucoup plus difficiles à estimer précisément que les covariances : Merton (1980) montre qu'il faut plusieurs décennies de données pour réduire suffisamment l'incertitude sur un rendement espéré, alors qu'une variance ou une covariance s'estime déjà correctement à partir de quelques mois à quelques années de rendements journaliers : contrairement à la variance, la précision de l'estimation d'un rendement moyen ne s'améliore pas en prenant des données plus fréquentes, seule une période calendaire plus longue aide. Le programme (2.1) ne dépendant que de Σ_t , la question posée par le mémoire porte donc naturellement sur la matrice de covariance elle-même, et sur sa décomposition $D_t R_t D_t$ introduite à la section 2.2.

Le lagrangien du programme (2.1) s'écrit

$$\mathcal{L}(w, \lambda) = w^\top \Sigma_t w - \lambda (\mathbf{1}^\top w - 1).$$

La condition de premier ordre $\partial \mathcal{L} / \partial w = 2\Sigma_t w - \lambda \mathbf{1} = 0$ donne $w = \frac{\lambda}{2} \Sigma_t^{-1} \mathbf{1}$ (l'inversibilité de Σ_t étant garantie par la définie-positivité). En réinjectant dans la contrainte budgétaire, $\frac{\lambda}{2} = 1 / (\mathbf{1}^\top \Sigma_t^{-1} \mathbf{1})$, d'où la solution fermée et unique

$$w_t^* = \frac{\Sigma_t^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma_t^{-1} \mathbf{1}}, \quad \text{Var}(w_t^{*\top} r_{t+1}) = \frac{1}{\mathbf{1}^\top \Sigma_t^{-1} \mathbf{1}}. \quad (2.2)$$

Aucune contrainte de positivité n'est imposée sur w_t^* : le portefeuille principal du mémoire autorise les ventes à découvert, un choix cohérent avec le protocole d'Engle, Ledoit et Wolf (2019) et qui permet d'exposer pleinement les conséquences des erreurs d'estimation sur Σ_t . Une robustesse imposant $w \geq 0$ est étudiée séparément (§2.6.1).

2.1.2 Le résultat d'Engle et Colacito : évaluer sans observer

On ne peut jamais observer directement la véritable matrice de covariance conditionnelle Σ_t : seuls les rendements réalisés r_{t+1} sont connus, une fois la date $t + 1$ atteinte. Il est donc impossible de calculer une distance entre un estimateur candidat $\hat{\Sigma}_t^{(k)}$ et la cible Σ_t , puisque cette cible reste inconnue. Engle et Colacito (2006) montrent pourtant que cette distance n'est pas nécessaire pour *classer* des estimateurs candidats du point de vue de l'allocation minimum-variance : ils établissent que le candidat produisant la plus faible variance réalisée de son portefeuille GMV associé est celui qui se rapproche le mieux de la véritable matrice Σ_t , au sens de ce critère précis. C'est ce résultat, énoncé formellement ci-dessous, qui justifie l'usage de la variance réalisée comme fonction de perte dans tout le reste du mémoire.

Proposition 1 (Engle et Colacito, 2006). *Soit Σ_t la vraie covariance conditionnelle, non observée en pratique, et w_t^* le portefeuille GMV oracle associé (portefeuille (2.2) construit à partir de cette véritable matrice, et donc lui-même inconnaisable). Pour tout portefeuille w satisfaisant $\mathbf{1}^\top w = 1$,*

$$w^\top \Sigma_t w \geq w_t^{*\top} \Sigma_t w_t^*,$$

avec égalité si et seulement si $w = w_t^$. En particulier, pour tout estimateur candidat $\hat{\Sigma}_t^{(k)}$ — potentiellement très différent de Σ_t , mais effectivement calculable, contrairement à Σ_t — et son portefeuille GMV associé $w_t^{(k)} = (\hat{\Sigma}_t^{(k)})^{-1} \mathbf{1} / (\mathbf{1}^\top (\hat{\Sigma}_t^{(k)})^{-1} \mathbf{1})$,*

$$\text{Var}(w_t^{(k)\top} r_{t+1}) \geq \text{Var}(w_t^{*\top} r_{t+1}),$$

avec égalité si et seulement si $w_t^{(k)}$ et w_t^ coïncident.*

Démonstration. Posons $v = w - w_t^*$. Comme w et w_t^* satisfont tous deux la contrainte budgétaire, $\mathbf{1}^\top v = 0$. Le portefeuille oracle w_t^* résout le programme (2.1) appliqué à la vraie matrice Σ_t : sa condition du premier ordre (section 2.1.1) s'écrit $2\Sigma_t w_t^* = \lambda \mathbf{1}$ pour un certain scalaire λ . En développant,

$$w^\top \Sigma_t w = (w_t^* + v)^\top \Sigma_t (w_t^* + v) = w_t^{*\top} \Sigma_t w_t^* + 2v^\top \Sigma_t w_t^* + v^\top \Sigma_t v.$$

Or $2v^\top \Sigma_t w_t^* = v^\top (2\Sigma_t w_t^*) = v^\top (\lambda \mathbf{1}) = \lambda (\mathbf{1}^\top v) = 0$ puisque $\mathbf{1}^\top v = 0$. Il reste donc

$$w^\top \Sigma_t w - w_t^{*\top} \Sigma_t w_t^* = v^\top \Sigma_t v \geq 0,$$

avec égalité si et seulement si $v = 0$, c'est-à-dire $w = w_t^*$, car Σ_t est définie positive.

La proposition 1 a une conséquence directe et utile : classer des estimateurs candidats $\hat{\Sigma}_t^{(k)}$ par la variance *réalisée* (hors échantillon) de leur portefeuille GMV associé fournit un ordre cohérent avec l'objectif d'allocation, sans jamais requérir d'observer Σ_t . Engle et Colacito (2006, p. 5) résument eux-mêmes ce que prouve leur résultat : « *the conditional variance of every optimized portfolio will be greater than or equal to the conditional variance of the portfolio optimized on the true covariance matrix [...] Correct covariance information will allow the investor to achieve lower volatility or higher return or both* ». Le résultat *ne dit pas* quel $\hat{\Sigma}_t^{(k)}$ est le plus proche de Σ_t au sens d'une norme matricielle quelconque : il dit que celui qui produit la plus faible variance réalisée du portefeuille est celui qui sert le mieux l'objectif de minimisation du risque, ce qui est précisément le critère pertinent pour répondre à la problématique du mémoire. C'est cette proposition qui fonde tout le protocole d'évaluation des sections 2.6 et 2.7.

2.2 La décomposition $\Sigma_t = D_t R_t D_t$

2.2.1 Définition

Soit Σ_t une matrice symétrique définie positive de dimension $N \times N$. On pose

$$D_t = \text{diag}\left(\sqrt{(\Sigma_t)_{11}}, \dots, \sqrt{(\Sigma_t)_{NN}}\right), \quad R_t = D_t^{-1} \Sigma_t D_t^{-1}.$$

Proposition 2 (Validité et unicité de la décomposition). *R_t est une matrice de corrélation valide (diagonale unité, symétrique, définie positive), et le couple (D_t, R_t) ainsi défini est l'**unique** couple (matrice diagonale à coefficients strictement positifs, matrice de corrélation) tel que $\Sigma_t = D_t R_t D_t$.*

Démonstration. Pour tout i , l'élément diagonal de R_t vaut $(R_t)_{ii} = (\Sigma_t)_{ii} / (\Sigma_t)_{ii} = 1$, puisque $(D_t)_{ii} = \sqrt{(\Sigma_t)_{ii}}$ par construction : la diagonale de R_t est donc bien unité. Sa symétrie découle directement de celle de Σ_t , D_t étant diagonale donc symétrique. Pour la définie-positivité, soit $x \in \mathbb{R}^N$, $x \neq 0$, et $y = D_t^{-1}x : y \neq 0$ car D_t est inversible (coefficients diagonaux strictement positifs), et

$$x^\top R_t x = x^\top D_t^{-1} \Sigma_t D_t^{-1} x = y^\top \Sigma_t y > 0$$

puisque $\Sigma_t \succ 0$. R_t est donc bien une matrice de corrélation valide.

Pour l'unicité, supposons $\Sigma_t = D_1 R_1 D_1 = D_2 R_2 D_2$ pour deux couples admissibles. Comme $(R_1)_{ii} = (R_2)_{ii} = 1$, les éléments diagonaux donnent $(\Sigma_t)_{ii} = (D_1)_{ii}^2 = (D_2)_{ii}^2$ pour tout i , d'où $(D_1)_{ii} = (D_2)_{ii} = \sqrt{(\Sigma_t)_{ii}}$ (racine carrée positive unique) : $D_1 = D_2 \equiv D_t$. En multipliant $\Sigma_t = D_1 R_1 D_1$ à gauche et à droite par D_t^{-1} , il vient $R_1 = D_t^{-1} \Sigma_t D_t^{-1} = R_2$. Le couple (D_t, R_t) est donc bien l'unique solution.

Élément par élément, cette décomposition s'écrit simplement

$$\text{Cov}(r_i, r_j) = \sigma_i \rho_{ij} \sigma_j \quad \text{pour } i \neq j,$$

avec $(R_t)_{ii} = 1$ sur la diagonale : c'est cette séparation entre écart-types et corrélation, triviale terme à terme, que la proposition 2 formalise et garantit unique. Cela signifie surtout que D_t et R_t peuvent être estimés séparément, chacun par son propre modèle, sans jamais se recouper : changer le modèle retenu pour D_t ne modifie jamais R_t , et inversement. C'est cette indépendance qui rend possible la grille factorielle du mémoire (section 2.5).

2.2.2 Portée pratique de la décomposition

La proposition 2 justifie que l'on puisse, sans perte de généralité ni ambiguïté, remplacer le problème de prévision d'une matrice Σ_{t+1} de dimension $N(N+1)/2$ par deux sous-problèmes strictement séparés : prévoir N volatilités individuelles (D_{t+1} , section 2.3) et prévoir une matrice de corrélation $N \times N$ (R_{t+1} , section 2.4). La figure 2.1 résume l'ordre exact des opérations à chaque date de rebalancement : la décomposition intervient *avant* la résolution du programme GMV (2.1), qui, lui, est appliqué de façon rigoureusement identique (même solveur, même contrainte) à chacune des six matrices $\hat{\Sigma}_{t+1}^{(d,r)}$ obtenues en combinant les modèles des sections 2.3 et 2.4. Le GMV n'a ainsi jamais connaissance de la façon dont $\hat{\Sigma}_{t+1}$ a été construite : c'est ce qui garantit que seule la construction de D et R diffère entre les six cellules de la grille, condition nécessaire à une attribution factorielle propre (section 2.5).




FIGURE 2.1 – Ordre des opérations à une date de rebalancement t . La décomposition $D \times R$ (deux cases centrales) est la seule étape qui distingue les six cellules de la grille ; le solveur GMV et la logique de détention sont partagés.

2.3 Modèles de variances (brique D)

Les deux modèles retenus pour D_t prennent en entrée la fenêtre de rendements et produisent, pour chaque actif i , une volatilité prévue $\hat{d}_{i,t+1}$ et une série de résidus dévolatilisés $s_{i,t} = r_{i,t}/\hat{d}_{i,t}$ sur la fenêtre — ces résidus sont l'unique canal par lequel la brique D influence la brique R construite en aval (section 2.4).

2.3.1 Variance empirique glissante

Le modèle de référence : l'écart-type empirique de la fenêtre d'estimation,

$$\hat{d}_{i,t+1} = \sqrt{\frac{1}{T-1} \sum_{s=t-T+1}^t (r_{i,s} - \bar{r}_i)^2}, \quad T = 1250.$$

où

- $r_{i,s}$ est le rendement de l'actif i à la date s ;
- $\bar{r}_i$ est la moyenne des rendements de l'actif i sur la fenêtre.

Aucune dynamique n'est modélisée : la prévision à $t+1$ est simplement l'écart-type historique des T derniers jours.

2.3.2 GARCH(1,1)

Pour chaque actif i , indépendamment des $N-1$ autres, on ajuste un GARCH(1,1) à moyenne nulle (Engle, 1982 ; Bollerslev, 1986) :

$$r_{i,t} = \sqrt{h_{i,t}} z_{i,t}, \quad z_{i,t} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 1), \quad h_{i,t} = \omega_i + \alpha_i r_{i,t-1}^2 + \beta_i h_{i,t-1},$$

où

- $r_{i,t}$ est le rendement de l'actif i à la date t ;
- $h_{i,t} = \text{Var}_{t-1}(r_{i,t})$ est sa variance conditionnelle prévue à partir de l'information disponible en $t - 1$;
- $z_{i,t}$ est l'innovation standardisée qui en résulte.

Les trois paramètres, propres à chaque actif, ont chacun un rôle distinct :

- $\omega_i > 0$ fixe le niveau de variance de base ;
- $\alpha_i \geq 0$ mesure la réaction de la variance au carré du dernier rendement observé (un choc récent important pousse $h_{i,t}$ à la hausse) ;
- $\beta_i \geq 0$ mesure la persistance de la variance passée (combien de la variance d'hier se retrouve dans celle d'aujourd'hui).

Le modèle est estimé sous la contrainte de stationnarité $\alpha_i + \beta_i < 1$. L'hypothèse de moyenne nulle est standard sur données journalières, où la moyenne conditionnelle est négligeable devant la variance conditionnelle sur l'horizon considéré. L'estimation est menée par quasi-maximum de vraisemblance gaussienne (QML), robuste à une mauvaise spécification de la loi conditionnelle des innovations (Bollerslev et Wooldridge, 1992). La prévision de volatilité à un jour est $\hat{d}_{i,t+1} = \sqrt{\hat{h}_{i,t+1}}$, et les résidus standardisés en échantillon, $s_{i,t} = r_{i,t}/\sqrt{\hat{h}_{i,t}}$, alimentent la brique R lorsque $D = \text{GARCH}$. En cas d'échec de convergence ou de non-stationnarité estimée ($\hat{\alpha}_i + \hat{\beta}_i \geq 1$), un mécanisme de repli substitue, pour cet actif seul, la volatilité et les résidus empiriques, sans affecter les $N - 1$ autres. La fréquence de ce repli est rapportée comme diagnostic au chapitre 4.

L'horizon de prévision principal est d'un jour, alors que les poids calculés à la date de rebalancement sont détenus 21 séances. Ce choix, assumé, correspond au protocole le plus proche de la littérature de référence (Engle, Ledoit et Wolf, 2019) ; une robustesse à horizon 21 jours, obtenue en moyennant les 21 variances conditionnelles prévues puis en prenant la racine carrée, est rapportée séparément (chapitre 4).

Extension non retenue. Une brique fondée sur un modèle HAR (Corsi, 2009) de volatilité réalisée, alimentée par des données intrajournalières (Oxford-Man Institute ou équivalent), constituerait un prolongement naturel mais sort du périmètre matériel du mémoire, qui ne mobilise que des rendements journaliers ; elle est discutée au chapitre des limites et extensions.

2.4 Modèles de corrélations (brique R)

Les trois modèles de cette section prennent tous en entrée le panel de résidus dévolatilisés s_t produit par la brique D (empiriques si $D = \text{empirique}$, GARCH-standardisés si $D = \text{GARCH}$) et renvoient une matrice $N \times N$ de diagonale unité.

2.4.1 Corrélation empirique constante

$$\hat{R}_t^{\text{emp}} = \text{Corr}(s_{t-T+1}, \dots, s_t),$$

le coefficient de corrélation de Pearson usuel, calculé par paires sur l'ensemble de la fenêtre : une matrice constante à l'intérieur de la fenêtre, réestimée à chaque rebalancement.

2.4.2 Corrélation constante shrinkée (Ledoit–Wolf)

En dimension N non négligeable devant T , la corrélation empirique R_t^{emp} souffre d'un biais spectral caractéristique : ses plus grandes valeurs propres sont surestimées et ses plus petites sous-estimées (loi de Marčenko–Pastur), ce qui dégrade la qualité de Σ_t^{-1} précisément là où le GMV est le plus sensible.

Ledoit et Wolf (2004) contractent l'estimateur empirique bruité S vers une cible sphérique μI_N , où $\mu = \text{tr}(\Sigma)/N$ est la moyenne des vraies variances. Trois quantités gouvernent l'arbitrage : $\alpha^2 = \|\Sigma - \mu I_N\|_F^2$ (distance entre la vraie matrice et la cible), $\beta^2 = \mathbb{E}\|S - \Sigma\|_F^2$ (bruit d'échantillonnage de S) et $\delta^2 = \mathbb{E}\|S - \mu I_N\|_F^2$ (distance entre l'empirique et la cible), liées par l'identité $\delta^2 = \alpha^2 + \beta^2$, un théorème de Pythagore dans l'espace des matrices : $S - \mu I_N$ se décompose en la somme orthogonale $(S - \Sigma) + (\Sigma - \mu I_N)$ puisque $\mathbb{E}[S] = \Sigma$. L'estimateur de risque quadratique minimal est alors

$$\Sigma^* = \rho^* \mu I_N + (1 - \rho^*) S, \quad \rho^* = \frac{\beta^2}{\delta^2} :$$

l'intensité de contraction optimale. Plus S est bruitée (β^2 grand), plus on s'appuie sur la cible ; plus la vraie matrice est éloignée de la cible (α^2 grand), plus on conserve l'empirique. En pratique $\mu, \alpha^2, \beta^2, \delta^2$ sont inconnus et remplacés par leurs estimateurs consistants construits dans la fenêtre (formule fermée de Ledoit et Wolf, 2004, section 3), ce qui donne ρ_t .

Pour appliquer ce résultat à la seule brique R sans jamais affecter D , la procédure retenue ne shrinke pas directement Σ_t mais les résidus dévolatilisés $s_{i,t}$ déjà définis à la section 2.3 (empiriques si $D = \text{empirique}$, GARCH-standardisés si $D = \text{GARCH}$), dont la variance empirique sur la fenêtre est proche de l'unité par construction. Sur ces données déjà standardisées, $\mu \approx 1$ et la cible sphérique se réduit à l'identité pure, si bien que la covariance shrinkée des $s_{i,t}$ s'écrit

$$C_t = \rho_t I_N + (1 - \rho_t) S_t, \quad \rho_t \in [0, 1],$$

avec S_t la covariance empirique des $s_{i,t}$ sur la fenêtre. C_t n'a toutefois pas nécessairement une diagonale exactement égale à 1, car le shrinkage agit mécaniquement sur les variances comme sur les covariances de S_t . Une renormalisation explicite est donc appliquée :

$$\hat{R}_t^{\text{LW}} = A_t C_t A_t, \quad A_t = \text{diag}(C_t)^{-1/2},$$

qui impose une diagonale unité exacte et *annule* tout effet résiduel du shrinkage sur la diagonale. C'est cette renormalisation, et non une propriété automatique du shrinkage, qui garantit que la brique D demeure totalement indépendante du choix de R : une covariance dont la diagonale serait, elle aussi, contractée mélangerait les deux effets et rendrait l'attribution factorielle du mémoire incohérente. Par construction, $\hat{R}_t^{\text{LW}}$ reste ainsi une matrice de corrélation valide (diagonale unité, symétrique, définie positive), même lorsque $N \geq T$, régime dans lequel $\hat{R}_t^{\text{emp}}$ est singulière.

2.4.3 Corrélation conditionnelle dynamique (DCC scalaire)

Contrairement aux deux modèles précédents, le DCC (Engle, 2002) produit une *séquence* de corrélations conditionnelles R_t , variant y compris à l'intérieur d'une même

fenêtre d'estimation. L'estimation suit la procédure en deux étapes usuelle : (i) les résidus dévolatilisés s_t sont obtenus par GARCH univarié (section 2.3.2) ; (ii) une pseudo-corrélation Q_t suit la récurrence scalaire, avec ciblage de corrélation (*correlation targeting*),

$$Q_t = (1 - \alpha - \beta) C + \alpha s_{t-1} s_{t-1}^\top + \beta Q_{t-1}, \quad \alpha, \beta \geq 0, \alpha + \beta < 1,$$

où

- C est la corrélation empirique inconditionnelle des résidus sur la fenêtre (la cible vers laquelle Q_t revient en l'absence de choc) ;
- $s_{t-1} s_{t-1}^\top$ est le produit extérieur des résidus dévolatilisés de la date précédente.

Comme pour le GARCH, les deux paramètres jouent des rôles distincts :

- α mesure la réaction de la corrélation au choc le plus récent ;
- β mesure sa persistance dans le temps.

Q_t n'est pas elle-même de diagonale unité ; on la renormalise en une véritable corrélation par

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}.$$

Les paramètres (α, β) sont estimés par maximum de vraisemblance gaussienne sur l'ensemble du chemin $\{R_t\}$, sous contrainte $\alpha, \beta \geq 0$ et $\alpha + \beta < 0,999$ (bornant la persistance strictement en deçà de l'intégration complète). En grande dimension ($N \geq 30$), la vraisemblance complète, qui requiert l'inversion d'une matrice $N \times N$ à chaque date, devient numériquement coûteuse et instable ; le protocole bascule alors vers une vraisemblance *composite*, somme des vraisemblances bivariées des paires d'actifs adjacentes (Pakel et al., 2021 ; approche reprise par Engle, Ledoit et Wolf, 2019 pour la grande dimension), en temps linéaire en N . Cette approximation dépend en principe de l'ordre des colonnes du panel ; ce point, non encore testé, est signalé explicitement au chapitre des limites.

Statut de la cellule $D_{\text{emp}} \times R_{\text{DCC}}$. Le DCC s'estimant nécessairement sur des résidus GARCH-standardisés, il n'existe en toute rigueur qu'une seule série R_t^{DCC} possible. La cellule combinant D_{emp} et R_{DCC} (section 2.5) est donc une construction **contrefactuelle d'attribution** : on réutilise exactement la même série R_t^{DCC} que celle de la cellule GARCH×DCC, en ne substituant que la diagonale. Cela rend la différence entre ces deux cellules interprétable comme un effet de D seule, à R^{DCC} rigoureusement identique, condition indispensable à une lecture en différences valide (section 2.5).

2.5 La grille de croisements et sa lecture en différences

Le croisement des deux modèles de D (section 2.3) et des trois modèles de R (section 2.4) engendre $2 \times 3 = 6$ matrices de covariance distinctes $\widehat{\Sigma}_t^{(d,r)} = \widehat{D}_t^{(d)} \widehat{R}_t^{(d,r)} \widehat{D}_t^{(d)}$, résumées au tableau 2.1.

TABLE 2.1 – La grille $D \times R$

$D \setminus R$	empirique	Ledoit–Wolf	DCC
empirique	(1)	(2)	(3)
GARCH(1,1)	(4)	(5)	(6)

Chaque cellule produit, par le protocole de backtest de la section 2.6, une série de portefeuilles GMV et une variance réalisée hors échantillon L_k (perte quadratique moyenne, section 2.7.1). La grille permet de lire des **contrastes** qui isolent l'effet d'une seule brique à l'autre fixée :

$$\underbrace{L_4 - L_1}_{D|R=\text{emp}}, \quad \underbrace{L_5 - L_2}_{D|R=LW}, \quad \underbrace{L_6 - L_3}_{D|R=DCC}, \quad \underbrace{L_2 - L_1}_{R=LW|D=\text{emp}}, \quad \underbrace{L_5 - L_4}_{R=LW|D=\text{GARCH}},$$

ainsi que les contrastes symétriques pour le DCC, et un terme d'**interaction** au sens du plan factoriel 2×2 standard,

$$(L_5 - L_4) - (L_2 - L_1) = L_5 - L_4 - L_2 + L_1,$$

qui mesure si l'effet du shrinkage sur R dépend du modèle de D retenu (et réciproquement). Cette identité est une conséquence purement algébrique du plan d'expérience : elle n'est pas empruntée à Engle et Colacito (2006) ni à Engle, Ledoit et Wolf (2019), qui fondent respectivement la fonction de perte (section 2.1.2) et les briques économétriques auxquelles ces contrastes sont appliqués (sections 2.3 et 2.4), mais jamais la grille factorielle elle-même. Cette dernière constitue la contribution méthodologique propre du mémoire.

2.6 Protocole de backtest

Le protocole suit une fenêtre glissante, sans aucune information future. À chaque date de rebalancement t , la fenêtre d'estimation est constituée strictement des $T = 1\,250$ rendements *antérieurs* à t : la date t elle-même est exclue de l'estimation, condition qui garantit qu'aucune observation future n'entre dans le calcul de $\hat{\Sigma}_t$. Le rebalancement a lieu toutes les 21 séances (approximativement un mois de bourse). Entre deux rebalancements, le nombre de titres détenus est constant mais leurs poids dérivent mécaniquement avec les prix ; le turnover à la date de rebalancement suivante compare les poids cibles nouvellement calculés aux poids *effectivement dérivés*, non aux anciens poids cibles.

À chaque rebalancement, l'univers des N actifs retenus est celui des N plus gros dollar-volumes moyens sur la fenêtre d'estimation, un proxy de capitalisation liquide cohérent avec Engle, Ledoit et Wolf (2019). Ce choix garantit lui aussi l'absence d'information future dans la sélection de l'univers. Les six cellules de la grille partagent, à chaque date, exactement le même univers et la même fenêtre : seules les briques D et R diffèrent (section 2.2.2), condition nécessaire à la validité des contrastes de la section 2.5.

Les métriques rapportées, en complément du critère principal (écart-type annualisé réalisé), sont : le rendement moyen annualisé, le ratio rendement/risque, le turnover moyen, la concentration ($\|w_t\|_2$), l'exposition brute ($\|w_t\|_1$) et la fraction de positions vendeuses.

2.6.1 Robustesse : contrainte long-only

Une seconde version du programme (2.1), avec $w \geq 0$ ajouté aux contraintes, est estimée séparément (chapitre 4). Sans solution fermée dès qu'une contrainte de positivité est active, elle est résolue numériquement par SLSQP (*Sequential Least Squares Quadratic Programming*), un algorithme itératif qui part d'une répartition initiale des poids et progresse par petits pas vers l'optimum tout en respectant à chaque étape les contraintes

linéaires du programme. Le portefeuille non contraint demeure le résultat principal du mémoire ; le long-only permet de vérifier si les conclusions d’attribution survivent lorsque l’optimiseur ne peut plus exploiter l’erreur d’estimation via le levier et les ventes à découvert.

Les contraintes de poids constituent en effet elles-mêmes une forme de régularisation implicite : Jagannathan et Ma (2003) montrent que forcer $w \geq 0$ équivaut mathématiquement à résoudre le problème non contraint avec une matrice de covariance où les covariances des actifs concernés auraient été réduites, très précisément, de la quantité nécessaire pour ramener leur poids à zéro plutôt que négatif. Or ce sont justement les covariances les plus élevées, donc les plus susceptibles d’être gonflées par le bruit d’échantillonnage, qui poussent un actif vers un poids négatif dans le programme non contraint : la contrainte corrige ainsi automatiquement, sans shrinkage explicite, précisément les estimations les plus fragiles.

2.7 Inférence statistique et économique

2.7.1 Perte quadratique et test de Diebold–Mariano

La proposition 1 établit que le bon critère de classement est la vraie variance $w^\top \Sigma_t w$: c’est un résultat de population, qui ne se calcule qu’avec la véritable covariance Σ_t , jamais observée. Il reste donc à relier ce critère théorique à une quantité que l’on peut réellement mesurer une fois le temps passé.

Écrivons le rendement futur du portefeuille k sous la forme $\pi_{t+1}^{(k)} = m_t^{(k)} + u_{t+1}^{(k)}$, avec $\mathbb{E}[u_{t+1}^{(k)} \mid \mathcal{F}_t] = 0$ et $\mathbb{E}[(u_{t+1}^{(k)})^2 \mid \mathcal{F}_t] = \text{Var}_t(\pi_{t+1}^{(k)})$ par définition même de la variance conditionnelle. Le poids $w_t^{(k)}$ étant fixé et connu à la date t , un seul rendement réalisé, une fois centré et élevé au carré, est donc un estimateur bruité mais *non biaisé* de cette vraie variance conditionnelle : c’est ce qui autorise à estimer, puis à comparer entre candidats, une quantité par ailleurs inobservable, en moyennant ce carré sur de nombreuses dates hors échantillon.

En toute rigueur, ce centrage devrait s’effectuer sur la moyenne conditionnelle $m_t^{(k)}$, inconnue et variable dans le temps : comme pour l’hypothèse de moyenne nulle retenue pour le GARCH (section 2.3.2), la moyenne conditionnelle des rendements journaliers est négligeable devant leur variance conditionnelle sur l’horizon considéré, ce qui autorise à l’approximer par la moyenne empirique constante $\bar{\pi}^{(k)}$ calculée sur l’ensemble de l’échantillon d’évaluation. La perte retenue exploite directement cette approximation : les rendements du portefeuille sont centrés sur cette moyenne *sur l’échantillon d’évaluation*, puis élevés au carré,

$$\ell_t^{(k)} = \left(\pi_t^{(k)} - \bar{\pi}^{(k)} \right)^2, \quad \mathbb{E} \left[\ell_t^{(k)} \right] = \text{Var} \left(\pi_t^{(k)} \right).$$

Pour comparer un modèle candidat à un modèle de référence, on définit la différence de pertes $u_t = \ell_t^{\text{cand}} - \ell_t^{\text{réf}}$ et on teste $\mathbb{E}[u_t] = 0$ par régression de u_t sur une constante, avec écart-type robuste à l’hétéroscédasticité et à l’autocorrélation (HAC, Newey et West, 1987) à 22 retards, ce qui correspond approximativement à un mois de séances et reste donc cohérent avec la fréquence de rebalancement. La statistique de test (le t -stat de la constante) est de type Diebold et Mariano (1995), appliquée ici au contraste précis défini par la proposition 1. Par convention, une différence moyenne $\bar{u} < 0$ signifie que le candidat *réduit* le risque réalisé (préférable) ; $\bar{u} > 0$ signifie qu’il le *détériore*.

Une version pondérée, proposée par Engle et Colacito (2006) pour stabiliser la variance de la statistique de test, normalise la différence de pertes par les variances prédites des deux modèles :

$$\tilde{u}_t = \frac{u_t}{\sqrt{2\hat{\sigma}_{\text{cand},t}^2\hat{\sigma}_{\text{réf},t}^2}}, \quad \hat{\sigma}_{k,t}^2 = w_t^{(k)\top} \hat{\Sigma}_t^{(k)} w_t^{(k)}$$

la variance du portefeuille GMV *prédite* par le modèle candidat à la date de rebalancement. Elle est disponible sans coût supplémentaire, puisqu'elle est calculée au moment même de la résolution du programme GMV (2.1).

2.7.2 Valeur économique : coûts et *performance fee*

Un coût de transaction proportionnel au turnover est déduit du rendement brut à chaque date de rebalancement, $r_t^{\text{net}} = r_t - c \times \text{turnover}_t$, pour $c \in \{0; 0,5\%; 1\%\}$. Pour traduire en un montant unique l'écart entre deux modèles, à la fois en risque *et* en rendement net de coûts, on retient le *performance fee* de Fleming, Kirby et Ostdiek (2001), fondé sur une utilité quadratique de la richesse brute pour une aversion au risque γ ,

$$U_\gamma(r) = (1+r) - \frac{\gamma}{2(1+\gamma)}(1+r)^2,$$

et défini comme le montant fee qu'il faudrait retirer, jour après jour, au rendement du modèle candidat pour égaliser son utilité espérée à celle du modèle de référence :

$$\mathbb{E} \left[U_\gamma \left(r_t^{\text{cand}} - \text{fee} \right) \right] = \mathbb{E} \left[U_\gamma \left(r_t^{\text{réf}} \right) \right],$$

résolu numériquement par recherche de racine, puis exprimé en points de base annuels. Un fee positif signifie que l'investisseur accepterait de *payer* pour passer au modèle candidat ; un fee négatif signifie qu'il faudrait l'en compenser. Ce critère complète, sans jamais s'y substituer, le critère principal de la proposition 1, centré sur le risque et non sur le couple rendement/risque.

2.8 Hypothèses testables

Le protocole des sections précédentes permet de formuler cinq hypothèses, directement lisibles sur la grille de contrastes de la section 2.5, et confrontées aux résultats au chapitre suivant.

- H1** L'effet d'une prévision GARCH de D sur le risque réalisé est *ambigu ex ante* : la littérature classique (Engle, 1982 ; Bollerslev, 1986) prédit un gain via une meilleure adaptation aux régimes de volatilité, tandis que Bollerslev, Patton et Quaedly (2018) documentent un risque de bruit d'estimation amplifié par une réaction excessive à chaque observation. Le signe des contrastes $L_4 - L_1$, $L_5 - L_2$, $L_6 - L_3$ tranche empiriquement entre ces deux mécanismes concurrents.
- H2a** Le shrinkage linéaire de Ledoit et Wolf (2004) réduit la variance réalisée par rapport à la corrélation empirique, à D fixé : $L_2 < L_1$ et $L_5 < L_4$.
- H2b** Le DCC scalaire, dont la cible reste ici la corrélation empirique non régularisée, n'apporte pas de gain robuste par rapport à la corrélation empirique statique : conformément à Engle, Ledoit et Wolf (2019), qui montrent que le DCC seul (sans shrinkage sur sa cible) reste leur estimateur le moins performant parmi leurs variantes DCC, l'essentiel du gain de leur méthode provenant de la régularisation de la cible plutôt que de la dynamique elle-même.

- H3** Puisque $\Sigma_t = D_t R_t D_t$ combine D et R de façon multiplicative et non additive, une erreur de prévision sur D et une erreur de prévision sur R n'ont aucune raison de s'annuler indépendamment l'une de l'autre : Halbleib et Voev (2016) montrent que l'absence de biais de chaque brique prise séparément ne suffit pas à garantir l'absence de biais de la covariance reconstruite, sauf si les deux erreurs sont non corrélées entre elles. Le mémoire teste si cette interaction théorique se manifeste empiriquement dans la grille.
- H4** La hiérarchie « la volatilité compte davantage que la corrélation », documentée par Chopra et Ziemba (1993) sur un exercice de sensibilité théorique à $N = 10$ actifs (et non un backtest empirique), et illustrée en dimension deux par Engle et Colacito (2006), n'est établie par ces deux papiers qu'en toute petite dimension. Sur la base d'un argument distinct, la malédiction de la dimension sur l'estimation cross-sectionnelle de R (loi de Marčenko–Pastur, déjà mobilisée section 2.4), le mémoire prédit que cette hiérarchie se resserre ou s'inverse lorsque N croît.

3 Données

3.1 Univers

L'univers est constitué des plus grandes capitalisations liquides du S&P 500 : 341 tickers, figés à l'avance pour garantir la reproductibilité, répartis sur six blocs sectoriels (technologie, financières, santé, consommation, énergie/matériaux/ industrie, utilities/REITs/communication). La sélection retient des constituants *actuels* de l'indice projetés sur leur historique complet : le mémoire est donc exposé à un **biais du survivant** : les entreprises sorties de l'indice avant 2025 (faillite, rachat, retrait) n'apparaissent pas dans le panel, ce qui tend à surestimer légèrement le rendement moyen et à sous-estimer le risque de queue réalisé sur la période. Une base avec compositions historiques exactes (type CRSP) traiterait ce biais à la racine, mais excède le périmètre matériel du mémoire ; le biais est déclaré explicitement ici et n'est à aucun moment présenté comme éliminé.

Trois tailles d'univers sont étudiées, $N \in \{50, 100, 200\}$, sélectionnées *dynamiquement* à chaque date de rebalancement parmi les actions retenues après nettoyage (§3.2), et non fixées une fois pour toutes au début de l'échantillon. Le critère de sélection est le plus gros dollar-volume moyen sur la fenêtre d'estimation, un proxy de capitalisation liquide cohérent avec le protocole d'Engle, Ledoit et Wolf (2019).

3.2 Source et nettoyage

Les prix de clôture ajustés (dividendes et opérations sur titres) et les volumes sont téléchargés depuis Yahoo Finance, par lots avec reprise automatique en cas d'échec de téléchargement. La période demandée est le 3 janvier 2000 au 31 décembre 2025 ; la borne de fin étant exclusive côté Yahoo, le panel s'arrête effectivement le 30 décembre 2025.

Un ticker est exclu du panel final si (i) son premier prix valide est postérieur au 31 mars 2000, ou (ii) sa proportion de valeurs manquantes sur toute la période dépasse 2 %. Les valeurs manquantes résiduelles (jours fériés locaux décalés, interruptions ponctuelles de cotation) sont alors propagées par la dernière valeur connue (*forward-fill*). Sur les 341 tickers demandés, 281 sont retenus (60 exclus, essentiellement des introductions en bourse postérieures à 2000). Le panel nettoyé ne contient, in fine, **aucune valeur manquante résiduelle**, condition nécessaire au calcul direct des rendements logarithmiques $r_t = \ln(P_t/P_{t-1})$.

Point non traité à ce stade. Le filtrage de paires quasi-dupliquées (deux classes d'actions d'un même émetteur, corrélation de paire $> 0,95$) envisagé initialement n'est pas encore appliqué : la règle d'exclusion actuelle ne porte que sur la date de première cotation et le taux de valeurs manquantes. L'univers retenu ne contient, à l'inspection, aucune paire de classes d'actions évidente (pas de structure à deux classes de type Alphabet ou

TABLE 3.1 – Construction du panel

Tickers demandés	341
Actions retenues après nettoyage	281
Jours de rendements	6 479
Période effective	28 mars 2000 – 30 décembre 2025
Valeurs manquantes résiduelles	0

Source : Yahoo Finance.

Berkshire Hathaway), mais ce garde-fou reste à ajouter formellement avant la version finale si l'univers venait à être régénéré ou étendu.

3.3 Protocole temporel

La fenêtre d'estimation glissante compte $T = 1\,250$ séances (environ cinq ans de bourse), et le portefeuille est rééquilibré toutes les 21 séances (environ un mois). La première date hors échantillon est le 21 mars 2005 ; l'échantillon d'évaluation hors échantillon couvre ainsi 5 229 rendements journaliers sur 249 dates de rebalancement, jusqu'à fin décembre 2025. Le tableau 3.2 résume ce découpage.

TABLE 3.2 – Fenêtre glissante et échantillon hors échantillon

Fenêtre d'estimation T	1 250 séances
Rebalancement	tous les 21 séances
Première date hors échantillon	21 mars 2005
Rendements journaliers hors échantillon	5 229
Dates de rebalancement	249

3.4 Statistiques descriptives

Le tableau 3.3 rapporte les statistiques descriptives moyennes, en coupe transversale sur les 281 actions du panel, calculées sur les rendements journaliers logarithmiques annualisés à 252 séances.

TABLE 3.3 – Statistiques descriptives (moyenne cross-section, 281 actions, échantillon complet)

Rendement annualisé moyen	9,83 %
Volatilité annualisée moyenne	34,05 %
$(min - max)$	$(18,77 \% - 61,13 \%)$
Asymétrie (<i>skewness</i>) moyenne	-0,51
Aplatissement (<i>kurtosis</i>) moyen	21,19

Le *skewness* négatif et le fort excès d'aplatissement (largement au-dessus de 3, la valeur d'une loi normale) confirment sur ce panel les faits stylisés usuels des rendements actions à fréquence journalière, à savoir une asymétrie vers les pertes extrêmes et des

queues épaisses. Ces faits stylisés justifient a priori la modélisation de l'hétéroscédasticité conditionnelle plutôt qu'une volatilité constante (première des « deux maladies » de l'estimation de covariance évoquées en introduction).

3.4.1 Corrélation moyenne par régime

Le tableau 3.4 rapporte la corrélation de paire moyenne (sur les $\binom{281}{2} = 39\,340$ paires) au sein de chacune des cinq sous-périodes du protocole d'évaluation (chapitre 2, §2.6).

TABLE 3.4 – Corrélation moyenne de paire par sous-période

Sous-période	Bornes	Corrélation moyenne
<i>pre_crise</i>	2005–2007	0,287
<i>crise_2008</i>	2008–2009	0,489
<i>inter</i>	2010–2019	0,371
<i>covid</i>	2020–2021	0,489
<i>post</i>	2022–2025	0,308
Échantillon complet	2000–2025	0,336

Sous-périodes définies au chapitre 2 (§2.6).

La corrélation moyenne *bondit* d'environ 0,29–0,37 en période calme à 0,49 lors des deux épisodes de crise (2008, Covid). C'est une illustration directe, sur ce panel, de l'effet bien documenté de hausse conjointe de la volatilité et de la corrélation en période de tension (« *volatility-in-correlation effect* »). C'est cette dynamique que le DCC (§2.4.3) cherche à capturer, et c'est aussi ce qui rend l'estimation de R particulièrement sensible au régime de marché : une corrélation supposée constante sur une fenêtre de cinq ans mélange nécessairement des régimes très différents.

3.4.2 Ratio N/T des configurations

Le ratio N/T gouverne directement l'ampleur du biais spectral de la corrélation empirique (loi de Marčenko–Pastur, §2.4.2) et donc la valeur attendue de la régularisation. Le tableau 3.5 le rapporte pour les trois tailles d'univers étudiées, à $T = 1\,250$ fixé.

TABLE 3.5 – Ratio N/T par configuration

N	50	100	200
N/T	0,040	0,080	0,160

Le ratio quadruple entre $N = 50$ et $N = 200$ à T fixé : c'est le levier principal par lequel le mémoire fait varier, de façon contrôlée, l'intensité de l'erreur d'estimation cross-sectionnelle affectant la brique R , condition nécessaire pour tester l'hypothèse H4 (chapitre 2, §2.8), selon laquelle la hiérarchie entre l'importance de D et de R se déplace lorsque la dimension croît.

4 Résultats

Ce chapitre présente les résultats de la grille factorielle $D \times R$ introduite au chapitre 2, pour un univers de $N \in \{50, 100, 200\}$ actions américaines sur la période hors échantillon 2005–2025 (fenêtre $T = 1250$ jours, rebalancement mensuel de 21 séances). Le critère principal reste, conformément au cadre d’Engle et Colacito (2006), l’écart-type annualisé des rendements réalisés du portefeuille minimum-variance globale (GMV), calculé sans contrainte de vente à découvert. La lecture suit neuf axes : classement descriptif, attribution à D , attribution à R , interaction, effet de dimension, régimes de marché, turnover/coûts, confrontation aux hypothèses, puis robustesses (les limites proprement dites sont discutées séparément au chapitre 5).

4.1 Classement descriptif des six cellules

Le tableau 4.1 rapporte l’écart-type annualisé réalisé pour chacune des six combinaisons de la grille $\widehat{\Sigma}_t^{(d,r)} = \widehat{D}_t^{(d)} \widehat{R}_t^{(d,r)} \widehat{D}_t^{(d)}$.

TABLE 4.1 – Écart-type annualisé des rendements GMV réalisés (%)

Cellule	$N = 50$	$N = 100$	$N = 200$
(1) Variance empirique $\times$ Corrélation empirique	13,93	13,70	12,89
(2) Variance empirique $\times$ Ledoit–Wolf	13,85	13,59	12,70
(3) Variance empirique $\times$ DCC	14,10	13,97	13,20
(4) GARCH(1,1) $\times$ Corrélation empirique	14,53	14,44	13,59
(5) GARCH(1,1) $\times$ Ledoit–Wolf	14,51	14,40	13,53
(6) GARCH(1,1) $\times$ DCC	14,57	14,60	13,55

Grille $D \times R$ (chapitre 2), échantillon complet 2005–2025 (chapitre 3).

La cellule (2) — variance empirique roulante combinée au shrinkage linéaire de Ledoit et Wolf (2004) sur la corrélation — domine pour les trois dimensions. Les quatre cellules utilisant le GARCH(1,1) univarié comme brique de variance sont systématiquement les plus risquées, quelle que soit la brique de corrélation associée. Ce classement descriptif appelle une attribution : le gain apparent de la cellule (2) provient-il de la brique D , de la brique R , ou des deux ?

4.2 Effet de la volatilité (D)

Le tableau 4.2 isole l’effet du passage d’une variance empirique à une prévision GARCH(1,1) à un jour, à corrélation fixée, par un test de type Diebold–Mariano/Engle–Colacito avec covariance HAC Newey–West (22 retards).

TABLE 4.2 – Effet de D (GARCH – empirique), à R fixé

Contraste	$N = 50$		$N = 100$		$N = 200$	
	DM	p	DM	p	DM	p
$D \mid R = \text{emp}$	2,33	2,0 %	2,29	2,2 %	2,12	3,4 %
$D \mid R = \text{LW}$	2,54	1,1 %	2,49	1,3 %	2,55	1,1 %
$D \mid R = \text{DCC}$	1,62	10,5 %	1,81	7,0 %	1,30	19,5 %

Test de Diebold–Mariano/Engle–Colacito, erreurs HAC Newey–West 22 retards (chapitre 2).

Dans les six cas du tableau 4.2, la différence de perte entre la cellule GARCH et la cellule empirique est positive : le GARCH(1,1) à un jour *détériore* le risque réalisé par rapport à la variance empirique roulante, plutôt qu’il ne l’améliore comme le supposait l’hypothèse initiale. L’écart est statistiquement fiable — le test de Diebold–Mariano rejette l’hypothèse d’un écart nul au seuil de 5 % — lorsque la corrélation est empirique ou shrinkée par Ledoit–Wolf, et ce sur les trois dimensions (p entre 1,1 % et 3,4 %) ; il reste du même signe mais ne franchit pas ce seuil lorsque la corrélation est modélisée par DCC (p entre 7,0 % et 19,5 %). Ce résultat va à l’encontre de l’hypothèse initiale et n’est pas maquillé : une hypothèse rejetée est un résultat scientifique.

Il se comprend à la lumière de l’argument de Bollerslev, Patton et Quaedvlieg (2018) sur le bruit de mesure des signaux de volatilité quotidiens. Une prévision GARCH réagit, par construction, à chaque nouvelle observation de rendement ; une partie de cette réaction reflète du bruit d’estimation plutôt qu’un véritable changement de risque. Sans mécanisme d’atténuation de ce bruit — leur modèle HARQ en propose un —, le signal quotidien peut se révéler plus nuisible qu’utile une fois injecté directement dans une optimisation qui l’exploite telle quelle : la prévision empirique, plus lisse par construction, s’avère ici plus fiable pour construire le portefeuille que la prévision GARCH, plus réactive mais aussi plus bruitée.

4.3 Effet de la corrélation (R)

Le tableau 4.3 rapporte les contrastes symétriques sur la brique de corrélation.

TABLE 4.3 – Effet de R , à D fixé

Contraste	$N = 50$		$N = 100$		$N = 200$	
	DM	p	DM	p	DM	p
$R = \text{LW} \mid D = \text{emp}$	−4,74	< 0,01 %	−6,57	< 0,01 %	−8,61	< 0,01 %
$R = \text{LW} \mid D = \text{GARCH}$	−6,96	< 0,01 %	−9,18	< 0,01 %	−8,30	< 0,01 %
$R = \text{DCC} \mid D = \text{emp}$	1,21	22,6 %	2,32	2,0 %	2,00	4,5 %
$R = \text{DCC} \mid D = \text{GARCH}$	0,40	69,2 %	1,18	24,0 %	−0,39	69,9 %

Test de Diebold–Mariano/Engle–Colacito, erreurs HAC Newey–West 22 retards (chapitre 2).

Le shrinkage linéaire de Ledoit–Wolf réduit systématiquement et très significativement la perte réalisée, quel que soit D et N . Le DCC, à l’inverse, ne procure aucun gain stable : il détériore significativement le risque à $N = 100$ et 200 lorsque D est empirique, et n’apporte de gain robuste dans aucune configuration sous GARCH. Cette hiérarchie —

une corrélation *constante mais bien régularisée* dominant une corrélation *dynamique mais plus bruitée* — reproduit à l’identique, par une attribution factorielle propre plutôt que par comparaison de modèles « tout-en-un », le constat d’Engle, Ledoit et Wolf (2019, tableau 5) : leur CCC-NL (corrélation constante, shrinkée non linéairement) bat leur DCC-S (corrélation dynamique, cible non shrinkée). Le mémoire systématise cette intuition en isolant explicitement la brique responsable du gain.

4.4 Interaction $D \times R$

Le tableau 4.4 rapporte les contrastes d’interaction factorielle standards $L_{GARCH,R'} - L_{GARCH,R} - L_{emp,R'} + L_{emp,R}$. Conformément à la fiche de sources méthodologiques du mémoire, cette identité est une conséquence algébrique du plan factoriel 2×2 , non un résultat spécifique d’Engle–Colacito (2006) ou d’Engle–Ledoit–Wolf (2019). Le même test de Diebold–Mariano/Engle–Colacito, avec correction HAC Newey–West (22 retards), est appliqué ici directement à la série des contrastes d’interaction — par exemple, pour $D \times LW$, à la série $u_t = (\ell_{5,t} - \ell_{4,t}) - (\ell_{2,t} - \ell_{1,t})$ — plutôt qu’à la seule moyenne rapportée au tableau 4.4.

TABLE 4.4 – Interactions $D \times R$ (écart de perte quadratique moyenne $\times 10^{-6}$, statistique DM, p-value)

Interaction	$N = 50$			$N = 100$			$N = 200$		
	Écart	DM	p	Écart	DM	p	Écart	DM	p
$D \times LW$	0,51	2,94	0,3 %	0,69	4,02	0,01 %	1,36	6,22	$< 0,01$ %
$D \times DCC \mid emp$	-1,47	-0,97	33,0 %	-1,28	-0,88	38,0 %	-3,64	-1,76	7,8 %
$D \times DCC \mid LW$	-1,98	-1,30	19,3 %	-1,96	-1,40	16,3 %	-4,99	-2,55	1,1 %

Test de Diebold–Mariano/Engle–Colacito appliqué à la série des contrastes d’interaction, erreurs HAC Newey–West 22 retards (chapitre 2).

En magnitude, les interactions restent nettement plus petites que l’effet principal de D (entre 0,5 et 5×10^{-6} , contre 6 à 9×10^{-6} pour $D \mid R$) : sur ce plan, D et R agissent en grande partie de façon additive. Face à l’effet principal de R , la comparaison est moins nette : l’interaction $D \times LW$ ($0,5$ à $1,4 \times 10^{-6}$) est du même ordre de grandeur que $R = LW \mid D = GARCH$ ($0,3$ à $0,6 \times 10^{-6}$), et même supérieure sur les trois dimensions. L’additivité entre D et R est donc une bonne approximation vis-à-vis de l’effet D , mais plus discutable vis-à-vis de l’effet R . Surtout, l’interaction $D \times LW$ est *statistiquement significative* sur les trois dimensions malgré sa petite taille : l’effet du shrinkage n’est donc pas rigoureusement identique selon que la volatilité est empirique ou GARCH, même si l’écart reste économiquement modeste. Les deux interactions impliquant le DCC, à l’inverse, ne sont pas significatives (à l’exception d’un cas limite à $N = 200$).

4.5 Effet de la dimension N

Les figures 4.1 et 4.2 illustrent l’évolution des écarts-types réalisés et des effets d’attribution avec N .

Le gain du shrinkage Ledoit–Wolf croît en valeur absolue avec N (de $-0,83 \times 10^{-6}$ à $N = 50$ à $-1,95 \times 10^{-6}$ à $N = 200$) : c’est le résultat central du mémoire au regard de la problématique. Lorsque le rapport N/T augmente, l’erreur d’estimation cross-sectionnelle




FIGURE 4.1 – Écart-type annualisé réalisé par cellule et par dimension N .

de la corrélation empirique se détériore (biais des valeurs propres, argument de Ledoit et Wolf 2004), et la régularisation prend d'autant plus d'importance. La détérioration causée par le GARCH, en revanche, reste du même ordre de grandeur sur les trois dimensions : c'est cohérent avec le fait que le GARCH univarié est ajusté actif par actif et ne souffre pas directement de la malédiction cross-sectionnelle qui touche l'estimation de R .

4.6 Régimes de marché

La décomposition en cinq sous-périodes (*pre_crise* 2005–2007, *crise_2008*, *inter* 2010–2019, *covid* 2020–2021, *post* 2022–2025) montre que le gain de Ledoit–Wolf est gagnant dans la majorité des périodes et dimensions, particulièrement robuste à $N = 200$ y compris en 2008 et pendant le Covid. Le GARCH peut ponctuellement aider avant la crise (notamment à $N = 100$) mais se détériore fortement en 2008. Le DCC ne présente de gain stable dans aucune sous-période. Le faible nombre d'observations de certaines sous-périodes (en particulier 2008–2009 et 2020–2021) limite la puissance statistique : l'ampleur économique et le signe sont rapportés systématiquement en complément de la significativité, sans surinterprétation d'une p-value isolée.

4.7 Turnover, exposition et valeur économique

Le GARCH et le DCC augmentent fortement le turnover (jusqu'à $\times 6$ par rapport à la cellule empirique), tandis que Ledoit–Wolf le réduit légèrement. Le tableau 4.6 traduit ces coûts en valeur économique (*performance fee* de Fleming–Kirby–Ostdiek, aversion au risque $\gamma = 10$, $N = 100$) : un fee positif signifie que l'investisseur accepterait de payer pour le modèle candidat.

Sans coûts, le GARCH obtient un fee positif malgré un risque réalisé plus élevé, uniquement grâce à un rendement moyen supérieur sur l'échantillon — un résultat qui ne doit pas se substituer à l'évaluation Engle–Colacito, centrée sur le risque. Dès qu'un coût de transaction réaliste est appliqué, le turnover élevé du GARCH inverse radicalement le fee (-3111 points de base à 1 %). Le DCC connaît le même renversement, tout aussi




FIGURE 4.2 – Effets d’attribution D/R par dimension N .

Cellule	Turnover	Exposition brute
(1) emp $\times$ emp	0,471	3,33
(2) emp $\times$ LW	0,437	3,17
(3) emp $\times$ DCC	2,146	3,12
(4) GARCH $\times$ emp	2,809	2,92
(5) GARCH $\times$ LW	2,750	2,87
(6) GARCH $\times$ DCC	2,973	3,13

TABLE 4.5 – Turnover mensuel moyen et exposition brute ($N = 100$)

marqué : un fee positif sans coûts (+93,2 points de base) qui devient fortement négatif dès qu’un coût réaliste est appliqué (−2 207 points de base à 1 %), cohérent avec son turnover élevé (tableau précédent) et avec l’avertissement de Santos (2019, chapitre 1, §1.5) sur le caractère souvent délétère, net de coûts, de la composante hors-diagonale d’une matrice de covariance sophistiquée. Le gain de Ledoit–Wolf, à l’inverse, *croît* avec les coûts (de +19,6 à +63,3 points de base) car il combine risque réalisé plus faible et turnover plus faible. L’ordre de grandeur de ce dernier gain (quelques dizaines de points de base par an) est cohérent avec les 60 à 170 points de base annuels nets de coûts rapportés par Bollerslev, Patton et Quaadvlieg (2018) pour des architectures DRD comparables, ce qui apporte une plausibilité externe à l’estimation.

4.8 Confrontation aux hypothèses

- **H1** (effet ambigu *ex ante* d’une prévision GARCH de D) : tranchée en faveur du second mécanisme. À l’horizon principal d’un jour, le GARCH(1,1) détériore significativement le risque réalisé, confirmant le mécanisme de bruit d’estimation amplifié de Bollerslev, Patton et Quaadvlieg (2018) plutôt que le gain d’adaptation aux régimes attendu de la littérature classique.
- **H2a** (le shrinkage Ledoit–Wolf réduit le risque, D fixé) : *confirmée*, significative-

TABLE 4.6 – Performance fee annuel net de coûts (points de base, $\gamma = 10$, $N = 100$)

Contraste	$c = 0 \%$	$c = 0,5 \%$	$c = 1 \%$
$D \mid R = \text{emp}$ (GARCH vs emp)	+130,6	−1373,8	−3110,8
$R = \text{LW} \mid D = \text{emp}$ (LW vs emp)	+19,6	+40,8	+63,3
$R = \text{DCC} \mid D = \text{emp}$ (DCC vs emp)	+93,2	−984,3	−2207,3

Méthode de Fleming–Kirby–Ostdiek (chapitre 2), $N = 100$.

ment, sur les trois dimensions.

- **H2b** (le DCC seul, ciblant la corrélation empirique, n’apporte pas de gain robuste) : *confirmée* : le DCC ne surpasse pas la corrélation empirique statique, cohérent avec Engle, Ledoit et Wolf (2019), qui montrent que le DCC sans shrinkage sur sa cible reste leur variante la moins performante.
- **H3** (interaction $D \times R$ non nulle, prédite par la combinaison multiplicative $\Sigma_t = D_t R_t D_t$ selon Halbleib et Voev, 2016) : *confirmée* pour l’interaction $D \times \text{LW}$, statistiquement significative sur les trois dimensions malgré sa petite taille ; non confirmée dans l’ensemble pour les interactions impliquant le DCC, à l’exception d’un cas limite à $N = 200$. En magnitude, ces interactions restent d’un ordre de grandeur inférieur à l’effet principal de D (additivité approximative en niveau), mais leur significativité statistique montre que les erreurs de D et de R ne sont pas non corrélées entre elles, exactement la condition que Halbleib et Voev (2016) identifient comme nécessaire à l’absence d’interaction.
- **H4** (la hiérarchie D/R se resserre ou s’inverse avec N) : *partiellement confirmée* : l’avantage de Ledoit–Wolf croît avec N , cohérent avec la malédiction de la dimension sur R ; l’effet GARCH reste stable en ordre de grandeur, cohérent avec une estimation univariée non affectée par N .

4.9 Robustesses

Les deux robustesses — horizon de prévision GARCH et contrainte long-only — ont d’abord été testées à $N = 100$ seul, puis étendues aux trois dimensions de la grille principale ($N = 50, 100, 200$), pour vérifier si les conclusions de robustesse elles-mêmes dépendent de N . Elles nuancent les résultats de la section précédente sans les renverser sur leur point central, mais avec une hétérogénéité selon N qui n’apparaissait pas dans le sous-échantillon $N = 100$ initial.

Horizon de prévision GARCH. Remplacer la prévision à un jour par la moyenne des variances prévues sur 21 jours (horizon aligné sur la détention) laisse l’effet $D \mid R = \text{emp}$ significatif à $N = 100$ (DM= 2,20, $p = 2,8\%$ contre DM= 2,29, $p = 2,2\%$ à un jour), mais celui-ci *devient non significatif* au seuil de 5% à $N = 50$ (DM= 1,69, $p = 9,1\%$ contre $p = 2,0\%$ à un jour) et à $N = 200$ (DM= 1,85, $p = 6,4\%$ contre $p = 3,4\%$ à un jour). Le décalage horizon/détention n’est donc pas la cause principale de la détérioration observée sous GMV non contraint, mais la robustesse de ce résultat à l’horizon de prévision est elle-même plus fragile aux extrémités de la grille de dimension qu’en son centre — un constat qui n’aurait pas pu être établi sur $N = 100$ seul.

Contrainte long-only. Sous un GMV sans vente à découvert ($\min w' \Sigma w$ sous $w \geq 0$), le tableau se modifie sensiblement, et de façon cohérente sur les trois dimensions. L’effet

$D \mid R = \text{emp}$ devient non significatif partout (DM= 1,36, $p = 17,4\%$ à $N = 50$; DM= 0,85, $p = 39,7\%$ à $N = 100$; DM= -1,27, $p = 20,3\%$ à $N = 200$, le signe du point estimé s'inversant même sans devenir significatif) : ce résultat suggère que la détérioration causée par le GARCH sous GMV non contraint provient principalement de l'interaction entre le bruit d'estimation GARCH et le levier/les positions courtes du portefeuille non contraint, plutôt que d'une faiblesse intrinsèque du signal GARCH, un constat qui se généralise aux trois dimensions.

L'effet $R = \text{LW} \mid D = \text{emp}$, lui, *survit* à la contrainte à $N = 100$ (DM= -3,66, $p = 2,5 \times 10^{-4}$) et $N = 200$ (DM= -4,76, $p = 2,0 \times 10^{-6}$), mais devient seulement marginal à $N = 50$ (DM= -1,83, $p = 6,7\%$). Son ampleur, en écart-type annualisé, est compressée d'environ un ordre de grandeur par la contrainte à chaque dimension : l'écart entre les cellules (1) empirique×empirique et (2) empirique×LW passe de 0,08 à 0,00 point à $N = 50$, de 0,11 à 0,01 point à $N = 100$, et de 0,19 à 0,02 point à $N = 200$. La contrainte de positivité agit donc, sur toute la grille, comme une régularisation implicite qui recouvre une grande partie — mais pas la totalité, sauf précisément à la dimension la plus faible — du bénéfice du shrinkage.

Cette régularisation implicite de la contrainte de positivité ne joue toutefois pas de façon uniforme sur la grille : l'effet GARCH s'effondre complètement (il devient non significatif aux trois dimensions), tandis que l'effet Ledoit–Wolf n'est que fortement compressé, sans disparaître à $N = 100$ et $N = 200$. Ce constat, pris dans son ensemble, n'est pas propre à l'échantillon retenu ici, et se vérifie sur l'ensemble de la grille de dimensions du mémoire autant que dans la littérature externe. Dom, Howard, Jansen et Lohre (2025) documentent exactement ce phénomène sur les constituants du S&P 500 (1990–2021) : l'écart de volatilité ex-post entre le meilleur et le pire des sept estimateurs testés (empirique, shrinkage linéaire/non linéaire, RiskMetrics, DCC non-linéairement shrinké, modèles à facteurs) est d'environ 3,4 points sous GMV non contraint (14,3% à 10,9%), contre seulement 0,5 point sous GMV contraint long-only avec pénalité de coûts (13,4%–13,9%). Ils attribuent cela au shrinkage implicite qu'introduit toute contrainte de poids (Jagannathan et Ma, 2003) — un argument théorique déjà mobilisé dans ce mémoire (chapitre 2, section sur la robustesse long-only) qui trouve ici une double confirmation empirique, indépendante par le panel et la période, du résultat obtenu au paragraphe précédent. Leur étude ne décompose cependant jamais la variance et la corrélation séparément : chacun de leurs estimateurs (par exemple DCC-NLS) reste un paquet complet, ce qui laisse entier l'apport spécifique de l'attribution factorielle $D \times R$ développée dans ce mémoire. Ces résultats restent soumis à plusieurs limites, discutées au chapitre 5.

5 Limites et extensions

5.1 Limites

Les résultats du chapitre précédent restent soumis à quatre limites principales.

Biais du survivant. L'univers est construit à partir d'une liste de tickers *actuels* du S&P 500, projetée sur l'ensemble de l'historique (chapitre 3, §3.1). Les entreprises sorties de l'indice avant 2025 (faillite, rachat, retrait) n'apparaissent pas dans le panel, ce qui tend à surestimer légèrement le rendement moyen réalisé et à sous-estimer le risque de queue effectivement supporté par un investisseur sur la période. Une base de données avec compositions historiques exactes (type CRSP) traiterait ce biais à la racine, mais excède le périmètre matériel de ce mémoire.

Approximation de la vraisemblance composite du DCC. En grande dimension ($N \geq 30$), l'estimation du DCC (chapitre 2, §2.4.3) repose sur une vraisemblance composite : la somme des vraisemblances bivariées des paires d'actifs *adjacentes* dans le panel. Cette approximation dépend, en principe, de l'ordre des colonnes ; ce point n'a pas été testé dans ce mémoire et reste une limite reconnue de l'estimation du DCC en grande dimension.

Fallback GARCH. Le taux de repli vers la volatilité empirique (estimation GARCH non stationnaire ou non convergente) est en moyenne de l'ordre de 3 % des ajustements sur l'échantillon instrumenté, avec des pointes ponctuelles nettement plus élevées sur certaines fenêtres. Ce mécanisme protège le protocole d'un plantage, mais introduit une hétérogénéité de méthode entre actifs à l'intérieur d'une même cellule GARCH qui n'est pas explorée plus avant ici.

Coûts de transaction fixés a priori. Les coûts retenus (0, 0,5 et 1 % du turnover) sont ceux du protocole initial, volontairement élevés pour tester la robustesse des conclusions : une robustesse avec des coûts plus réalistes, exprimés en points de base plutôt qu'en pourcentages ronds, permettrait d'affiner l'estimation de la valeur économique nette (chapitre 2, §2.7.2).

5.2 Extensions

Plusieurs prolongements naturels découlent directement de ces limites et du protocole du chapitre 2.

Tester la sensibilité à l'ordre des colonnes du DCC composite. Réestimer le DCC sur quelques fenêtres avec plusieurs permutations de l'ordre des actifs permettrait de quantifier directement la limite signalée ci-dessus, à un coût de calcul mesuré (quelques fenêtres, pas l'ensemble du protocole).

Shrinkage non linéaire. Remplacer le shrinkage linéaire de Ledoit et Wolf (2004) par sa version non linéaire (Ledoit et Wolf, 2012, 2017, chapitre 1, §1.3) constituerait un

septième modèle naturel de la brique R , potentiellement plus performant encore que le shrinkage linéaire déjà dominant dans ce mémoire.

Brique de volatilité réalisée. Une brique D fondée sur un modèle HAR (Corsi, 2009) de volatilité réalisée, alimentée par des données intrajournalières, constituerait un prolongement direct de la comparaison avec Halbleib et Voev (2016, chapitre 1, §1.5), mais nécessite des données non mobilisées ici.

Robustesse géographique. Reproduire le protocole sur un univers non américain (STOXX Europe 600, envisagé dans le plan initial du mémoire) permettrait de tester si la hiérarchie observée, à savoir un shrinkage de la corrélation qui domine la dynamique de la volatilité, est spécifique au marché américain ou se généralise.

Au-delà de la paire volatilité/corrélation. Plus largement, la méthode d'attribution factorielle développée dans ce mémoire consiste à croiser systématiquement plusieurs modèles concurrents pour chaque brique d'une décomposition économétrique établie, puis à lire les contrastes qui en résultent. Cette méthode ne se limite pas à la décomposition $D \times R$: elle pourrait s'appliquer à toute situation où la littérature propose plusieurs remèdes concurrents à des problèmes distincts, sans jamais les avoir opposés dans un même plan d'expérience.

Conclusion

Réponse à la problématique

Sur l'échantillon étudié — 281 actions américaines, 2005–2025, univers de taille $N \in \{50, 100, 200\}$ — les prévisions de volatilité et de corrélation ne jouent *pas* un rôle symétrique dans l'efficacité du GMV. Dans le protocole principal (portefeuille non contraint, horizon de prévision GARCH à un jour), la régularisation de la corrélation par shrinkage linéaire (Ledoit et Wolf, 2004) réduit systématiquement et très significativement le risque réalisé, avec un gain qui *croît* en valeur absolue avec la dimension N ; la dynamique GARCH(1,1) de la volatilité, à l'inverse, *détériore* significativement ce même risque sur les trois dimensions ; le DCC n'apporte de gain robuste dans aucune configuration. Dans cet échantillon, l'efficacité du GMV dépend donc davantage de la réduction de l'erreur d'estimation cross-sectionnelle des corrélations que de l'introduction d'une dynamique plus sophistiquée des volatilités.

Cette hiérarchie se nuance, sans se renverser sur son point central, sous la robustesse long-only (chapitre 4, §4.9) : la contrainte de positivité, qui agit comme une régularisation implicite (Jagannathan et Ma, 2003), resserre fortement l'écart entre les six cellules de la grille et rend l'effet délétère du GARCH non significatif sur les trois dimensions — suggérant que sa détérioration, sous portefeuille non contraint, provient largement de son interaction avec le levier et les positions vendeuses extrêmes que l'optimiseur exploite, plutôt que d'une faiblesse intrinsèque du signal GARCH lui-même. L'avantage du shrinkage, lui, survit à la contrainte à $N = 100$ et $N = 200$ — bien que son ampleur soit compressée d'environ un ordre de grandeur — et n'est plus que marginal à $N = 50$ ($p = 6,7\%$), là où l'échantillon transversal est le plus petit et l'erreur d'estimation cross-sectionnelle la plus faible.

Les trois sous-questions

SQ1. Les gains documentés séparément par la littérature ne se confirment que *partiellement* sous un protocole unifié : le shrinkage de la corrélation se confirme et se renforce ; la dynamique GARCH de la volatilité, loin de se confirmer, se retourne significativement contre son hypothèse initiale ; le DCC ne se confirme pas. Un résultat défavorable à un modèle établi dans la littérature est ici traité comme un résultat scientifique à part entière, non comme une anomalie à corriger.

SQ2. La grille factorielle $D \times R$ attribue sans ambiguïté l'essentiel de la réduction de risque à la brique de corrélation R , et ce diagnostic est *stable* à travers les trois dimensions étudiées ; l'interaction entre les deux briques reste d'un ordre de grandeur inférieur aux effets principaux (chapitre 4, §4.4).

SQ3. La hiérarchie « la volatilité compte davantage », documentée en petite dimension par Chopra et Ziemba (1993) et par la construction bivariée d'Engle et Colacito (2006), ne

survit *pas* au passage à la dimension moyenne et grande étudiée ici : elle est directement contredite par le sens de l'effet dimension observé, cohérent avec l'intuition spectrale de Marčenko–Pastur : plus N/T augmente, plus l'erreur d'estimation cross-sectionnelle de la corrélation empirique se détériore, et plus la régularisation de R prend de l'importance relative face à la modélisation dynamique de D .

Portée pratique

Pour un gérant construisant un portefeuille minimum-variance sur un univers d'actions de taille moyenne à grande, ces résultats suggèrent de concentrer l'effort de modélisation sur la régularisation de la matrice de corrélation — une intervention peu coûteuse en calcul, qui réduit à la fois le risque réalisé *et* le turnover — plutôt que sur une dynamique de volatilité univariée sophistiquée, dont le bénéfice statistique, quand il existe, est ici annulé voire inversé par le turnover et les coûts de transaction qu'elle engendre (chapitre 4, §4.7). L'écart entre la conclusion obtenue sous portefeuille non contraint et sous portefeuille long-only rappelle par ailleurs qu'une conclusion méthodologique sur la valeur d'un estimateur de covariance n'est jamais indépendante des contraintes de portefeuille sous lesquelles elle est mesurée — un point que confirme, sur un panel et une période indépendants, Dom, Howard, Jansen et Lohre (2025).

Limites et pistes de recherche

Ces résultats restent soumis à des limites clairement identifiées — biais du survivant, approximation de vraisemblance composite du DCC en grande dimension, taux de fallback GARCH, coûts de transaction fixés a priori — et appellent des prolongements naturels, en premier lieu un test de sensibilité du DCC composite à l'ordre des colonnes. Le chapitre 5 détaille ces limites et ces pistes une à une.

Bibliographie

- Bollerslev (1986)** Bollerslev, T. (1986), « Generalized Autoregressive Conditional Heteroskedasticity », *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev (1990)** Bollerslev, T. (1990), « Modelling the Coherence in Short-Run Nominal Exchange Rates : A Multivariate Generalized ARCH Model », *Review of Economics and Statistics*, 72(3), 498–505.
- Bollerslev, Patton et Quaedvlieg (2018)** Bollerslev, T., Patton, A. J. et Quaedvlieg, R. (2018), « Modeling and Forecasting (Un)Reliable Realized Covariances for More Reliable Financial Decisions », *Journal of Econometrics*, 207(1), 71–91. DOI : 10.1016/j.jeconom.2018.05.004.
- Bollerslev et Wooldridge (1992)** Bollerslev, T. et Wooldridge, J. M. (1992), « Quasi-Maximum Likelihood Estimation and Inference in Dynamic Models with Time-Varying Covariances », *Econometric Reviews*, 11(2), 143–172.
- Chopra et Ziemba (1993)** Chopra, V. K. et Ziemba, W. T. (1993), « The Effect of Errors in Means, Variances, and Covariances on Optimal Portfolio Choice », *Journal of Portfolio Management*, 19(2), 6–11.
- Corsi (2009)** Corsi, F. (2009), « A Simple Approximate Long-Memory Model of Realized Volatility », *Journal of Financial Econometrics*, 7(2), 174–196.
- De Nard, Ledoit et Wolf (2021)** De Nard, G., Ledoit, O. et Wolf, M. (2021), « Factor Models for Portfolio Selection in Large Dimensions : The Good, the Better and the Ugly », *Journal of Financial Econometrics*, 19(2), 236–257. DOI : 10.1093/jjfinec/nby033.
- Diebold et Mariano (1995)** Diebold, F. X. et Mariano, R. S. (1995), « Comparing Predictive Accuracy », *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dom, Howard, Jansen et Lohre (2025)** Dom, M. S., Howard, C., Jansen, M. et Lohre, H. (2025), « Beyond GMV : The Relevance of Covariance Matrix Estimation for Risk-Based Portfolio Construction », *Quantitative Finance*, 25(3), 403–419. DOI : 10.1080/14697688.2025.2468268.
- Engle (1982)** Engle, R. F. (1982), « Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation », *Econometrica*, 50(4), 987–1007.
- Engle (2002)** Engle, R. F. (2002), « Dynamic Conditional Correlation : A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models », *Journal of Business & Economic Statistics*, 20(3), 339–350. DOI : 10.1198/073500102288618487.
- Engle et Colacito (2006)** Engle, R. F. et Colacito, R. (2006), « Testing and Valuing Dynamic Correlations for Asset Allocation », *Journal of Business & Economic Statistics*, 24(2), 238–253. DOI : 10.1198/073500106000000017.

- Engle, Ledoit et Wolf (2019)** Engle, R. F., Ledoit, O. et Wolf, M. (2019), « Large Dynamic Covariance Matrices », *Journal of Business & Economic Statistics*, 37(2), 363–375. DOI : 10.1080/07350015.2017.1345683.
- Fleming, Kirby et Ostdiek (2001)** Fleming, J., Kirby, C. et Ostdiek, B. (2001), « The Economic Value of Volatility Timing », *Journal of Finance*, 56(1), 329–352.
- Fleming, Kirby et Ostdiek (2003)** Fleming, J., Kirby, C. et Ostdiek, B. (2003), « The Economic Value of Volatility Timing Using Realized Volatility », *Journal of Financial Economics*, 67(3), 473–509.
- Halbleib et Voev (2016)** Halbleib, R. et Voev, V. (2016), « Forecasting Covariance Matrices : A Mixed Approach », *Journal of Financial Econometrics*, 14(2), 383–417 (version de travail : CREATES Research Paper 2011-03). DOI : 10.1093/jjfinec/nbu031.
- Jagannathan et Ma (2003)** Jagannathan, R. et Ma, T. (2003), « Risk Reduction in Large Portfolios : Why Imposing the Wrong Constraints Helps », *Journal of Finance*, 58(4), 1651–1683.
- Ledoit et Wolf (2004)** Ledoit, O. et Wolf, M. (2004), « A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices », *Journal of Multivariate Analysis*, 88(2), 365–411. DOI : 10.1016/S0047-259X(03)00096-4.
- Ledoit et Wolf (2012)** Ledoit, O. et Wolf, M. (2012), « Nonlinear Shrinkage Estimation of Large-Dimensional Covariance Matrices », *Annals of Statistics*, 40(2), 1024–1060.
- Ledoit et Wolf (2017)** Ledoit, O. et Wolf, M. (2017), « Nonlinear Shrinkage of the Covariance Matrix for Portfolio Selection : Markowitz Meets Goldilocks », *Review of Financial Studies*, 30(12), 4349–4388.
- Markowitz (1952)** Markowitz, H. (1952), « Portfolio Selection », *Journal of Finance*, 7(1), 77–91.
- Merton (1980)** Merton, R. C. (1980), « On Estimating the Expected Return on the Market : An Exploratory Investigation », *Journal of Financial Economics*, 8(4), 323–361.
- Michaud (1989)** Michaud, R. O. (1989), « The Markowitz Optimization Enigma : Is ‘Optimized’ Optimal? », *Financial Analysts Journal*, 45(1), 31–42.
- Oh et Patton (2016)** Oh, D. H. et Patton, A. J. (2016), « High-Dimensional Copula-Based Distributions with Mixed Frequency Data », *Journal of Econometrics*, 193(2), 349–366. DOI : 10.1016/j.jeconom.2016.04.011.
- Pakel, Shephard, Sheppard et Engle (2021)** Pakel, C., Shephard, N., Sheppard, K. et Engle, R. F. (2021), « Fitting Vast Dimensional Time-Varying Covariance Models », *Journal of Business & Economic Statistics*, 39(3), 652–668. DOI : 10.1080/07350015.2020.1713795.
- Pouliasis et Papapostolou (2018)** Pouliasis, P. K. et Papapostolou, N. C. (2018), « Volatility and Correlation Timing : The Role of Commodities », *Journal of Futures Markets*, 38(11), 1407–1439. DOI : 10.1002/fut.21939.
- Newey et West (1987)** Newey, W. K. et West, K. D. (1987), « A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix », *Econometrica*, 55(3), 703–708.

Santos (2019) Santos, A. A. P. (2019), « Disentangling the Role of Variance and Covariance Information in Portfolio Selection Problems », *Quantitative Finance*, 19(1), 57–76. DOI : 10.1080/14697688.2018.1465197.

Annexe A — Liste des 281 actions retenues

Liste alphabétique des 281 tickers effectivement retenus après nettoyage (chapitre 3, §3.2), sur les 341 initialement demandés. Source : Yahoo Finance.

A, AAPL, ABT, ADBE, ADI, ADM, ADSK, AEE, AEP, AES, AFL, AIG, AJG, AKAM, ALB, ALL, AMAT, AMD, AME, AMGN, AMT, AMZN, AON, AOS, APA, APD, APH, ATO, AVB, AXP, AZO, BA, BAC, BAX, BBY, BDX, BEN, BF-B, BIIB, BK, BKNG, BLK, BMY, BRO, BSX, BXP, C, CAG, CAH, CAT, CB, CCI, CDNS, CHD, CI, CINF, CL, CLX, CMCSA, CMI, CMS, CNP, COF, COO, COP, COST, CPB, CSCO, CSX, CTAS, CTSH, CVS, CVX, D, DE, DGX, DHI, DHR, DIS, DLTR, DOV, DTE, DUK, DVN, EBAY, ECL, ED, EIX, EL, EMN, EMR, EOG, EQR, ES, ESS, ETN, EW, EXC, F, FAST, FCX, FDX, FE, FFIV, FITB, FRT, GD, GE, GILD, GIS, GL, GLW, GPC, GS, GWW, HAL, HAS, HBAN, HD, HIG, HON, HPQ, HRL, HST, HSY, HUM, IBM, IDXX, IEX, INCY, INTC, INTU, IP, IRM, IT, ITW, IVZ, JBL, JNJ, JPM, KEY, KIM, KLAC, KMB, KO, LEN, LH, LHX, LLY, LMT, LNT, LOW, LRCX, LUV, MAA, MAR, MAS, MCD, MCHP, MCK, MCO, MDT, MKC, MLM, MMM, MNST, MO, MOS, MRK, MS, MSFT, MSI, MTB, MTD, MU, NEE, NEM, NI, NKE, NOC, NSC, NTAP, NTRS, NUE, NVDA, NVR, O, OKE, OMC, ORCL, ORLY, OXY, PCAR, PEG, PEP, PFE, PG, PGR, PH, PHM, PKG, PLD, PNC, PNR, PNW, POOL, PPG, PPL, PSA, PTC, QCOM, REG, REGN, RF, RJF, RL, RMD, ROK, ROP, ROST, RSG, RTX, SBAC, SBUX, SCHW, SHW, SJM, SLB, SNPS, SO, SPG, SPGI, STLD, STT, STZ, SWK, SWKS, SYK, T, TAP, TDY, TER, TFC, TGT, TJX, TMO, TROW, TRV, TSCO, TSN, TXN, TXT, UDR, UHS, UNH, UNP, UPS, URI, USB, VLO, VMC, VRSN, VRTX, VTR, VZ, WAB, WAT, WDC, WEC, WELL, WFC, WHR, WM, WMB, WMT, WRB, WY, XEL, XOM, YUM, ZION